



Universidad de San Carlos de Guatemala
Facultad de Ingeniería
Escuela de Ingeniería en Ciencias y Sistemas

**DESARROLLO DE UN SISTEMA BASADO EN MACHINE LEARNING
PARA LA DETECCION TEMPRANA DE ESCENARIOS DE BAJO
RENDIMIENTO AGRICOLA EN ZONAS AGROCLIMATICAS DE
GUATEMALA**

Edgar Josías Cán Ajquejay

Asesorado por el Ing. Sergio Leonel Gomez Bravo

Guatemala, Mayo, 2026

**EN LA PARTE DEL MARCO TEORICO SE ENCONTRARA EL CONTENIDO,
SE USO LA PLANTILLA PARA MEJOR ORDEN
EN LA PAGINA 29 INICIA EL MARCO TEORICO**

UNIVERSIDAD DE SAN CARLOS DE GUATEMALA



FACULTAD DE INGENIERÍA

TÍTULO, TÍTULO TÍTULO TÍTULO TÍTULO TÍTULO TÍTULO, TÍTULO TÍTULO
TÍTULO, TÍTULO TÍTULO TÍTULO TÍTULO TÍTULO TÍTULO, TÍTULO TÍTULO
TÍTULO

TRABAJO DE GRADUACIÓN

PRESENTADO A LA JUNTA DIRECTIVA DE LA
FACULTAD DE INGENIERÍA
POR

NOMBRE COMPLETO DEL ESTUDIANTE EN NEGRITA
ASESORADO POR PROFESIÓN Y NOMBRE COMPLETO

AL CONFERÍRSELE EL TÍTULO DE

TÍTULO ACADÉMICO QUE OBTENDRÁ

GUATEMALA, MES Y AÑO

UNIVERSIDAD DE SAN CARLOS DE GUATEMALA
FACULTAD DE INGENIERÍA



NÓMINA DE JUNTA DIRECTIVA

DECANO	
VOCAL I	Ing. Xxxxx Xxxxx Xxxxx Xxxxx
VOCAL II	Ing. Xxxxx Xxxxx Xxxxx Xxxxx
VOCAL III	Ing. Xxxxx Xxxxx Xxxxx Xxxxx
VOCAL IV	Br. Xxxxx Xxxxx Xxxxx Xxxxx
VOCAL V	Br. Xxxxx Xxxxx Xxxxx Xxxxx
SECRETARIA	Ing. Xxxxx Xxxxx Xxxxx Xxxxx

TRIBUNAL QUE PRACTICÓ EL EXAMEN GENERAL PRIVADO

DECANO	De ese período
EXAMINADOR	Examinador 1
EXAMINADOR	Examinador 2
EXAMINADOR	Examinador 3
SECRETARIO	De ese período

HONORABLE TRIBUNAL EXAMINADOR

En cumplimiento con los preceptos que establece la ley de la Universidad de San Carlos de Guatemala, presento a su consideración mi trabajo de graduación titulado:

**TÍTULO, TÍTULO TÍTULO TÍTULO TÍTULO TÍTULO TÍTULO, TÍTULO TÍTULO
TÍTULO, TÍTULO TÍTULO TÍTULO TÍTULO TÍTULO TÍTULO, TÍTULO TÍTULO
TÍTULO**

Tema que me fuera asignado por la Dirección de la Escuela de Ingeniería (**nombre de la Escuela respectiva**), con fecha (**fecha de aprobación del protocolo o perfil de EPS**).

Nombre completo del estudiante

ACTO QUE DEDICO A:

Dios

Texto, texto texto texto.

Mis padres

Texto, texto texto texto.

Mis hermanas

Texto texto texto

Mi hermano

Texto texto texto texto

Mi abuelo

Texto texto texto texto (q. e. p. d.)

Mis amigos

Texto texto texto

Ingeniero

Texto texto texto.

AGRADECIMIENTOS A:

Universidad de San Carlos de Guatemala Texto texto texto

Mis amigos Texto texto texto

Ingenieros Texto texto texto

Mi novia Texto texto texto

ÍNDICE GENERAL

ÍNDICE DE ILUSTRACIONES

GLOSARIO

RESUMEN

OBJETIVOS

INTRODUCCIÓN

1. **MARCO CONTEXTUAL: AGRICULTURA Y CLIMA EN GUATEMALA**
 - 1.1. Importancia del sector agrícola en la economía nacional
 - 1.2. Caracterización de las 8 regiones agroclimáticas (MAGA)
 - 1.3. Problemática de las anomalías térmicas y heladas agrícolas
 - 1.4. Vulnerabilidad de cultivos estratégicos (Maíz, Frijol, Café)
 - 1.5. El rol del INSIVUMEH y MAGA en la vigilancia climática
 - 1.6. Fenología y fases críticas de desarrollo ante el estrés térmico
 - 1.7. Contexto agroclimático del altiplano occidental como área de estudio
2. **MARCO TEÓRICO: MACHINE LEARNING Y DETECCIÓN DE ANOMALÍA**
 - 2.1. Fundamentos de Machine Learning para agricultura
 - 2.2. Aprendizaje supervisado vs. no supervisado
 - 2.3. Algoritmos para análisis de series temporales agroclimáticas
 - 2.3.1. Redes LSTM (Long Short-Term Memory)
 - 2.3.2. Árboles de decisión y XGBoost
 - 2.3.3. Modelos híbridos para predicción agroclimática
 - 2.4. Técnicas de detección de anomalías
 - 2.4.1. Isolation Forest
 - 2.4.2. Z-Score y Modified Z-Score
 - 2.5. Estado del arte de los sistemas de alerta temprana

agroclimática

- 2.5.1. Sistemas internacionales de referencia
- 2.5.2. Experiencias y referentes aplicables a Guatemala
- 2.6. Descomposición de series temporales: tendencia, estacionalidad y residuo
- 2.7. Arquitectura IoT y protocolos de comunicación para agricultura de precisión
 - 2.7.1. Arquitectura por capas: percepción, red, nube y aplicación
 - 2.7.2. Protocolo MQTT y modelo publish-subscribe
 - 2.7.3. LoRaWAN y redes LPWAN para zonas rurales
 - 2.7.4. Comparación con otras tecnologías de comunicación
 - 2.7.5. Edge computing y fog computing en monitoreo agrícola
- 2.8. Arquitectura de sistemas de soporte a decisiones y visualización de alertas
- 2.9. Consideraciones éticas y de privacidad de datos agroclimáticos

3. METODOLOGÍA Y PROCESAMIENTO DE DATOS

- 3.1. Enfoque metodológico de la investigación
- 3.2. Adquisición y procesamiento del dataset ERA5-Land
 - 3.2.1. Fuentes de datos climáticos: estaciones INSIVUMEH y ERA5-Land
 - 3.2.2. Descarga, limpieza y normalización de datos
 - 3.2.3. Validación de ERA5-Land con datos observados
- 3.3. Tratamiento de datos y limpieza de series temporales
 - 3.3.1. Integración de datos históricos y datos en tiempo real
 - 3.3.2. Alineación temporal y espacial de registros
 - 3.3.3. Tratamiento de valores faltantes e inconsistencias
- 3.4. Ingeniería de características para el modelo predictivo
 - 3.4.1. Horas frío, estrés térmico y variables derivadas

- 3.4.2. Incorporación de fases fenológicas como variables predictoras
 - 3.4.3. Descomposición STL y transformación de series
 - 3.5. Estrategia de entrenamiento, validación y ajuste de modelos
 - 3.6. Métricas de evaluación y validación de modelos
 - 3.6.1. Métricas de regresión: RMSE, MAE y R^2
 - 3.6.2. Métricas de clasificación: precisión, recall, F1-Score y matriz de confusión
- 4. **DISEÑO E IMPLEMENTACIÓN DEL PROTOTIPO**
 - 4.1. Arquitectura general del sistema predictivo
 - 4.2. Selección y justificación del área de estudio
 - 4.3. Diseño del pipeline de datos y flujo operacional del sistema
 - 4.4. Desarrollo del motor de detección de anomalías y generación de alertas
 - 4.5. Integración de sensores IoT y transmisión de datos
 - 4.6. Diseño de la interfaz de visualización y apoyo a la toma de decisiones
 - 4.7. Herramientas, frameworks y stack tecnológico utilizado
- 5. **ANÁLISIS DE RESULTADOS Y VALIDACIÓN**
 - 5.1. Evaluación del desempeño de los modelos
 - 5.2. Resultados de detección de anomalías térmicas
 - 5.3. Análisis de efectividad en la detección de riesgo de bajo rendimiento
 - 5.4. Validación del sistema de alertas en el caso de estudio
 - 5.5. Discusión sobre factibilidad, escalabilidad y limitaciones

CONCLUSIONES

RECOMENDACIONES

REFERENCIAS

ÍNDICE DE ILUSTRACIONES

FIGURAS

No se encontraron entradas de tabla de contenido.

TABLAS

Tabla 1.	Título de la tabla 1 ¡Error! Marcador no definido.
Tabla 2.	Título de tabla 2 ¡Error! Marcador no definido.

LISTA DE SÍMBOLOS

Símbolo	Significado
\$	Dólar
Gb	Giga Bite
Mb	Mega Bite

GLOSARIO

GoogleCloud

Texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto

Nube

Texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto

Streaming

Texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto

TSE

Texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto

RESUMEN

Texto texto texto texto texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto texto texto texto texto texto
texto Texto texto texto texto texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto texto texto texto texto texto

Texto texto texto texto texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto texto texto texto texto texto
texto Texto texto texto texto texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto texto texto texto texto texto

Texto texto texto texto texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto texto texto texto texto texto
texto Texto texto texto texto texto texto texto texto texto texto texto texto
Texto texto texto texto texto texto texto texto texto texto texto texto texto

OBJETIVOS

General

Desarrollar una solución tecnológica orientada a la identificación de escenarios de bajo rendimiento agrícola en Guatemala mediante el análisis de registros climáticos y métricas en tiempo real.

Específicos

1. Caracterizar el comportamiento climático y umbrales de riesgo en las zonas de interés a través del análisis de registros históricos.
2. Implementar un dispositivo de monitoreo para la obtención de variables ambientales locales en el sitio de estudio.
3. Evaluar el desempeño de modelos analíticos en la identificación de anomalías climáticas vinculadas al rendimiento agrícola.
4. Desarrollar una interfaz de visualización para el seguimiento de los indicadores generados por el sistema.

INTRODUCCIÓN

El proyecto consiste en el desarrollo de una solución tecnológica integral que combina Machine Learning (ML) e Internet de las Cosas (IoT) para la vigilancia agrícola. El sistema utiliza un dispositivo con sensores (humedad, temperatura) para capturar métricas del campo en tiempo real, las cuales se transmiten a una plataforma centralizada. Mediante modelos predictivos entrenados con datasets históricos del INSIVUMEH, el sistema compara las condiciones actuales con patrones de riesgo climático para detectar anomalías de forma temprana. Los resultados se visualizan en un dashboard de métricas que genera alertas automáticas, permitiendo una toma de decisiones informada antes de que el daño en los cultivos sea irreversible.

1. MARCO CONTEXTUAL: AGRICULTURA Y CLIMA EN GUATEMALA

1.1. Importancia del sector agrícola a nivel nacional

Guatemala ha construido su economía, desde hace varias décadas, sobre la tierra. La agricultura no es simplemente un sector productivo más: es el sostén de millones de familias rurales y una de las principales fuentes de divisas del país. Según datos del Banco de Guatemala (BANGUAT), la agricultura, ganadería y actividades hidrobiológicas cerraron 2022 representando alrededor del 9.31% del PIB nacional. Ese porcentaje, visto de forma aislada, podría parecer sencillo, sin embargo, no cuenta toda la historia: el sector emplea a más del 27% de la población económicamente activa y genera más de la mitad de los ingresos por exportaciones, concretamente el 51.29%.

En términos de producción, el PIB agrícola ha mostrado un crecimiento sostenido a lo largo de los últimos años. Entre 2013 y 2025, el promedio histórico ronda los 12,291.55 millones de quetzales, con una proyección que apunta a un pico de 14,990.36 millones de GTQ para el primer trimestre de 2025.

En términos de producción, el PIB agrícola ha mostrado un crecimiento sostenido a lo largo de los últimos años. Entre 2013 y 2025, el promedio histórico ronda los 12,291.55 millones de quetzales, con una proyección que apunta a un pico de 14,990.36 millones de GTQ para el primer trimestre de 2025.

Esa brecha no es solo económica. Cuando una sequía o una helada golpea esas zonas, el efecto no se mide en puntos del PIB, sino en hambre. El 59.8% de la población

guatemalteca enfrenta algún nivel de inseguridad alimentaria moderada o grave, y la mayoría de esas personas viven en zonas rurales dependientes de la lluvia y del ciclo agrícola. Por eso, modernizar el agro con herramientas de análisis y predicción no es solo una apuesta por la competitividad: es una necesidad urgente para reducir desigualdades que llevan generaciones arraigadas en el campo guatemalteco.

1.2. Las ocho regiones agroclimáticas de Guatemala

El Ministerio de Agricultura, Ganadería y Alimentación (MAGA) divide el territorio nacional en ocho regiones agroclimáticas, delimitadas según altitud, relieve, precipitación y temperatura media. Esta clasificación opera como herramienta técnica de planificación: orienta la selección de semillas, las fechas óptimas de siembra y cosecha, y el manejo de insumos agrícolas.

Tabla 1 Regiones agroclimáticas de Guatemala: fechas de inicio del ciclo agrícola y características principales

Región Agroclimática	Departamentos Representativos	Inicio del Ciclo Agrícola Sugerido	Características Principales
Altiplano Occidental	San Marcos, Quetzaltenango, Totonicapán	06 de mayo al 15 de mayo	Alta incidencia de heladas; altitudes superiores a 2,000 msnm.
Altiplano Central	Guatemala, Chimaltenango, Sacatepéquez	11 de mayo al 20 de mayo	Clima templado; diversificación de hortalizas y café.
Bocacosta	San Marcos (sur), Quetzaltenango (sur)	11 de abril al 20 de abril	Alta pluviosidad; transición térmica entre costa y montaña.

Pacífico	Escuintla, Suchitepéquez, Retalhuleu	06 de mayo al 15 de mayo	Temperaturas altas; riesgos de sequía y canícula prolongada.
Valles de Oriente	Zacapa, Chiquimula, El Progreso	11 de mayo al 20 de mayo	Déficit hídrico crítico; región más seca del país.
Norte (Petén)	Petén	16 de mayo al 25 de mayo	Clima tropical; expansión de frontera agrícola y ganadería.
Región Agroclimática	Departamentos Representativos	Inicio del Ciclo Agrícola Sugerido	Características Principales
Caribe	Izabal	25 de mayo al 05 de junio	Influencia marítima; riesgos de inundaciones por frentes fríos.
Franja Transversal	Alta Verapaz, Quiché (norte)	25 de mayo al 05 de junio	Muy húmedo; alta nubosidad y precipitaciones constantes.

Adaptado de *Perspectiva Agroclimática Temporada Mayo, Junio y Julio 2022*, por Ministerio de Agricultura, Ganadería y Alimentación (MAGA), 2022 (<https://www.maga.gob.gt/download/perspectiva-agro-22.pdf>).

La variabilidad entre regiones se agudiza por fenómenos como El Niño-Oscilación del Sur (ENOS), que en 2023 llevó a Guatemala a registrar el año más caluroso desde 1981, con una temperatura promedio nacional de 25.11 °C y una tendencia de calentamiento de 0.19 °C por década (INSIVUMEH, 2024). Frente a esto, el MAGA, a través del Centro de Información Estratégica Agropecuaria, implementa las Mesas Técnicas Agroclimáticas (MTA) en coordinación con sus delegaciones departamentales, mecanismo que en 2022 alcanzó cobertura del 100% del territorio nacional con más de 800 técnicos

capacitados maga (MAGA, 2022), y que para 2025 continúa operando como principal sistema de alerta temprana para el sector agropecuario (MAGA, 2025).

1.3. Anomalías térmicas y heladas agrícolas en Guatemala

En el altiplano guatemalteco, no todas las amenazas climáticas se manifiestan mediante precipitaciones. Las heladas agrícolas —definidas como eventos en los que la temperatura del aire desciende a 0 °C o menos— generan daños irreversibles en los tejidos vegetales debido a la formación de cristales de hielo dentro de las células. Guatemala enfrenta de manera recurrente este tipo de eventos hidrometeorológicos, cuya frecuencia e impacto se han intensificado en las últimas décadas en el contexto del cambio climático (SEGEPLAN, 2021).

Este fenómeno se presenta principalmente en zonas ubicadas por encima de los 1,600 msnm, aunque sus efectos más severos ocurren en altitudes superiores a los 2,200 msnm, particularmente en las regiones montañosas del país como la Sierra Madre y los Cuchumatanes. El Altiplano Central y Occidental, caracterizado por elevaciones entre 2,500 y 3,500 msnm, registra las temperaturas más bajas del territorio nacional, lo que incrementa su vulnerabilidad frente a las heladas (SEGEPLAN, 2021).

La temporada de heladas inicia tras la finalización de la época lluviosa y se intensifica entre los meses de diciembre y febrero, con posibles extensiones hasta marzo y abril (MAGA, 2021). Su ocurrencia está asociada a condiciones atmosféricas como cielos despejados, baja humedad y reducción del viento, que favorecen la pérdida de calor durante la noche.

En términos de exposición, diversas áreas agrícolas del país se encuentran en zonas de alta amenaza por heladas, afectando principalmente cultivos como hortalizas, granos básicos y café (MAGA, 2021). Estos eventos, junto con sequías y ciclones tropicales, constituyen una de las principales

causas de pérdidas en el sector agropecuario, impactando de forma recurrente a las poblaciones rurales más vulnerables (SEGEPLAN, 2021).

1.4. Vulnerabilidad de cultivos estratégicos (Maíz, Frijol, Café)

Se espera que el cambio climático reduzca significativamente la productividad del maíz, el frijol y el café en América Central, comprometiendo tanto los medios de vida de los pequeños productores como la seguridad alimentaria de miles de familias rurales (Viguera et al., 2019). En Guatemala, estos tres cultivos no son simplemente rubros económicos: son la base de la dieta nacional, la principal fuente de ingresos de la agricultura familiar y, en el caso del café, el motor de las exportaciones agropecuarias. Su vulnerabilidad térmica hace que cualquier anomalía climática tenga consecuencias directas sobre la producción y el bienestar rural.

- **Maíz (*Zea mays*)**

El maíz es el principal cultivo de granos básicos en Guatemala, con una contribución del 37.7% a la ingesta per cápita de energía y del 36.5% a la ingesta de proteína (ICTA, 2002). Su mayor exposición al riesgo térmico ocurre durante la polinización, etapa donde temperaturas superiores a 32 °C inhiben la viabilidad del polen, y por encima de 35 °C pueden desecar los estigmas — conocidos como "sedas"—, impidiendo la formación de granos (Corteva, s.f.). En el altiplano, la amenaza es inversa: el frío extremo ralentiza el metabolismo de la planta y las heladas tempranas pueden causar la muerte de la plántula antes de completar su ciclo. Las zonas maiceras ubicadas por encima de los 1,500 msnm tienen épocas de siembra diferenciadas y una alta

dependencia de las condiciones climáticas estacionales (ICTA, 2002).

- **Frijol (*Phaseolus vulgaris*)**

El frijol demanda la mayor cantidad de agua durante las etapas de floración y llenado de vainas, siendo especialmente sensible al déficit hídrico en esos períodos, lo que puede afectar severamente los rendimientos (Acción contra el Hambre, 2021). Su rango óptimo de temperatura oscila entre 20 °C y 25 °C, con un mínimo de 18 °C y un máximo de 28 °C (Acción contra el Hambre, 2021). Temperaturas por debajo del umbral mínimo durante la floración provocan el aborto de flores y una formación deficiente de vainas, mientras que el calor excesivo, frecuentemente combinado con estrés hídrico, deteriora la calidad nutricional y comercial del grano (DICTA, 2012).

- **Café (*Coffea arabica*)**

El café requiere condiciones térmicas estables para expresar su potencial productivo, con temperaturas promedio ideales entre 17 °C y 23 °C. El estrés por frío —por debajo de 10 °C— induce clorosis en las hojas jóvenes y paraliza el crecimiento vegetativo, comprometiendo no solo la cosecha del año en curso sino también el desarrollo de yemas florales para el ciclo siguiente (ICAFE, s.f.). El 81% de los pequeños productores guatemaltecos encuestados en zonas cafetaleras reportó que los cambios climáticos percibidos en la última década afectaron negativamente su producción (Viguera et al., 2019), evidencia que la vulnerabilidad

térmica del cultivo ya se está traduciendo en pérdidas concretas en campo.

1.5. El rol del INSIVUMEH y el MAGA en la vigilancia climática agrícola

La gestión del riesgo agroclimático en Guatemala no recae en una sola institución: es el resultado de una coordinación entre el INSIVUMEH como ente científico y el MAGA como brazo técnico de intervención en campo. Cada uno cumple una función distinta pero complementaria dentro del sistema de alerta temprana para el sector agropecuario.

El INSIVUMEH opera la red de monitoreo atmosférico del país, que incluye estaciones convencionales y automáticas distribuidas en el territorio nacional. Sus registros son la base con la que el MAGA elabora los análisis agroclimáticos mensuales, incluyendo el seguimiento de frentes fríos, acumulados de precipitación y pronósticos de temperatura mínima por departamento (MAGA/CIEA, 2026). Esta información alimenta directamente los productos técnicos que llegan a los productores.

Por su parte, el MAGA canaliza esos datos a través de la Dirección de Información Geográfica, Estratégica y Gestión de Riesgos (DIGEGR) y su Centro de Información Estratégica Agropecuaria (CIEA). El CIEA elabora perspectivas agroclimáticas mensuales que identifican las regiones con mayor riesgo de heladas, exceso de humedad o sequía, y determina los cultivos y municipios prioritarios para el monitoreo (MAGA/CIEA, 2026). Por ejemplo, el informe de enero 2026 identificó 75 municipios bajo vigilancia activa por riesgo de heladas, con énfasis en Huehuetenango, San Marcos, Quetzaltenango y Quiché, donde cultivos como hortalizas, café y pastos enfrentan mayor exposición (MAGA/CIEA, 2026).

Este flujo de información se concreta en las Mesas Técnicas Agroclimáticas (MTA), espacios donde técnicos del MAGA, representantes del INSIVUMEH y productores locales analizan conjuntamente los pronósticos para tomar decisiones de siembra, selección de variedades y manejo de riesgos (MAGA, 2022). Las recomendaciones del sistema incluyen alertas sobre condiciones que pueden provocar quemaduras foliares, retrasos en el crecimiento, reducción de rendimientos e impactos al sector pecuario por afectación de pastos y forrajes (MAGA/CIEA, 2026).

Sin embargo, el sistema tiene límites estructurales. La escala de los datos institucionales —elaborados a nivel departamental o regional— no ofrece la resolución espacial necesaria para orientar decisiones de agricultura de precisión a nivel de parcela. Esta brecha entre la información disponible y la granularidad que demanda el productor individual es uno de los principales desafíos pendientes del sistema de vigilancia agroclimática guatemalteco.

1.6. Fenología y fase Críticas de desarrollo ante el estrés térmico

La fenología agrícola estudia cómo los factores climáticos condicionan los ciclos biológicos de los cultivos. Entender estas fases es clave para el diseño de alertas tempranas, ya que el impacto de una anomalía térmica puede ser tolerable en un momento del ciclo y catastrófico en otro.

*Frijol (*Phaseolus vulgaris*)*

El ciclo del frijol avanza desde la germinación (V0) hasta la maduración (R9), pasando por etapas vegetativas y reproductivas. Las fases de mayor sensibilidad son la floración (R6), cuando la planta presenta la primera flor abierta, y el llenado de vainas (R8), que marca el inicio del crecimiento activo de

la semilla (SIAP, 2019). Las temperaturas óptimas oscilan entre 10 y 27 °C; fuera de ese rango, el cultivo experimenta aborto de flores, vainas deficientes o deterioro de la calidad del grano (SIAP, 2019).

Café (*Coffea arabica*)

El ciclo del café incluye floración, formación del fruto, expansión, granulación y maduración. Las variaciones en precipitación y temperatura están alterando las condiciones agroclimáticas óptimas requeridas para obtener los mayores rendimientos (Vignola et al., 2018). La granulación es la fase más crítica para la calidad: temperaturas extremas aceleran la maduración de forma artificial, resultando en granos de menor densidad y perfil sensorial deteriorado. Este efecto se prolonga al beneficiado, donde temperaturas superiores a 30 °C aceleran la fermentación pero dañan el embrión del grano, y por debajo de 10 °C la fermentación se desvía hacia perfiles no deseados (Soto, s.f.).

1.7. Contexto agroclimático del altiplano occidental como área de estudio

El Altiplano Occidental —que comprende departamentos como Quetzaltenango, San Marcos y Huehuetenango— se define por una topografía accidentada con altitudes que oscilan entre 2,500 y 3,500 msnm, registrando los niveles de temperatura más bajos del país

(SEGEPLAN, 2021). Esta región presenta el escenario más exigente para la producción agrícola: sus inviernos son severos, la presencia de microclimas es constante y las temperaturas mínimas absolutas históricas han alcanzado -4.6 °C en Quetzaltenango y -4.2 °C en Huehuetenango (MAGA/CIEA, 2026). Estas condiciones imponen un límite biológico estricto a los cultivos sensibles y obligan a los productores a tomar decisiones de siembra y protección con información climática muy precisa.

La selección de esta área como unidad de estudio para un sistema IoT de alerta temprana se justifica tanto por su alta densidad de población rural dependiente de cultivos sensibles, como por las limitaciones técnicas de los sistemas de monitoreo actuales. La integración del IoT e inteligencia artificial ha transformado la agricultura moderna al habilitar la agricultura de precisión, el monitoreo en tiempo real y la toma de decisiones basada en datos (Miller et al., 2025); sin embargo, persisten desafíos críticos como los altos costos de infraestructura, la interoperabilidad limitada y las restricciones de conectividad en zonas rurales (Miller et al., 2025). Un sistema de precisión en el Altiplano debe ser capaz de modelar la inversión térmica y el enfriamiento por radiación, fenómenos que ocurren cuando la pérdida de calor nocturna genera una inversión de temperatura entre las partes altas y bajas de las plantaciones, con efectos que varían significativamente según la ladera y la humedad relativa, haciendo insuficientes las estaciones meteorológicas regionales para predecir el impacto exacto a nivel de parcela. En ese contexto, los dispositivos IoT con redes LoRaWAN ofrecen al productor acceso a lecturas en tiempo real para la toma de decisiones y la optimización de recursos, con la ventaja de alcanzar incluso las fincas más remotas dentro de estas redes de monitoreo y control (IEEE, 2024).

2. MARCO TEORICO: MACHINE LEARNING Y DETECCION DE ANOMALIA

2.1. Fundamentos de Machine Learning para agricultura

El Machine Learning (ML) proporciona las herramientas computacionales para transformar datos crudos de sensores en conocimiento predictivo. En agricultura, su valor radica en la capacidad de modelar sistemas biológicos y climáticos que son inherentemente no lineales y de alta dimensionalidad. Los métodos estadísticos y basados en reglas convencionales son menos efectivos al trabajar con datos de gran volumen en contextos de alta dimensionalidad, limitación que los algoritmos de ML superan al aprender patrones novedosos en grandes conjuntos de datos (Ahmad et al., 2025). A diferencia de los modelos tradicionales, los algoritmos de ML mejoran su precisión a medida que se alimentan con más datos históricos y en tiempo real.

La integración del IoT y la inteligencia artificial ha transformado la agricultura moderna al habilitar la agricultura de precisión, el monitoreo en tiempo real y la toma de decisiones basada en datos, con modelos de aprendizaje automático como SVM, CNN y Random Forest aplicados a la optimización del riego, la fertilización y el manejo de plagas (Miller et al., 2025). En ese marco, las tecnologías IoT han permitido a los agricultores supervisar y controlar sus operaciones de forma remota, facilitando el monitoreo de cultivos, la gestión del suelo y el agua, y la aplicación de insumos con mayor precisión (Hassan et al., 2024).

2.2. Aprendizaje Supervisado vs No Supervisado

Los algoritmos de ML se dividen en dos grandes paradigmas según la disponibilidad de datos etiquetados, y ambos tienen aplicaciones complementarias en sistemas de alerta agroclimática.

El **aprendizaje supervisado** opera cuando se cuenta con registros históricos donde el resultado ya es conocido —por ejemplo, datos de temperatura de noches en las que efectivamente ocurrió una helada y se documentó daño foliar. En este contexto se emplean algoritmos de regresión para predecir variables continuas como la temperatura mínima esperada, o algoritmos de clasificación para emitir alertas binarias (Alerta/No Alerta). Marcos híbridos que combinan aprendizaje supervisado con detección de anomalías no supervisada han demostrado alta capacidad predictiva, aprovechando las fortalezas complementarias de ambos enfoques para mejorar la precisión en la identificación de eventos inusuales (Monteiro et al., 2025).

El **aprendizaje no supervisado** resulta fundamental cuando no se dispone de etiquetas previas o cuando se busca detectar anomalías "desconocidas". El algoritmo aprende el comportamiento normal del sistema y señala cualquier desviación significativa de esa norma, sin necesidad de haber visto ese tipo de evento antes. Isolation Forest es un método especialmente adecuado para este propósito, pues basa su funcionamiento en aislar observaciones anómalas en lugar de modelar el comportamiento habitual, con capacidad para procesar datos de alta dimensionalidad sin requerir etiquetas en el entrenamiento, lo que lo convierte en una herramienta idónea para el monitoreo en tiempo real en entornos variables.

(Ahmad et al., 2025). En el contexto agroclimático, esta característica es particularmente valiosa: permite detectar eventos extremos sin precedentes históricos exactos, como olas de calor en periodos tradicionalmente fríos o descensos térmicos abruptos fuera de temporada, donde un modelo supervisado carecería de ejemplos de entrenamiento.

2.3. Algoritmos para análisis de series temporales agroclimáticas

2.3.1. Redes LSTM (Long Short-Term Memory)

Las redes LSTM son una variante avanzada de las redes neuronales recurrentes (RNN) diseñadas para capturar dependencias a largo plazo en series temporales. Su arquitectura incluye puertas (*gates*) que regulan el flujo de información, permitiendo que el modelo retenga o descarte información de pasos anteriores según su relevancia para la predicción actual. En el contexto agroclimático, esto es especialmente valioso: una red LSTM puede "recordar" que las temperaturas de la semana previa han estado descendiendo progresivamente y usar esa tendencia acumulada para anticipar una helada inminente, incluso si la lectura de un solo instante no parecería alarmante.

La ecuación de la puerta de olvido (*forget gate*), que determina qué información del estado anterior se descarta, es:

$$f_t = \sigma(W_f * [h_{t-1}, x_t] + b_f)$$

donde σ es la función sigmoide, W_f es la matriz de pesos, h_{t-1} es el estado oculto del paso anterior, x_t es la entrada actual y b_f es el sesgo. Valores de f_t cercanos a 0 indican olvido total; valores cercanos a 1 indican retención completa (Hochreiter & Schmidhuber, 1997).

Las redes de sensores inalámbricos para monitoreo ambiental pueden beneficiarse de arquitecturas que combinan capas LSTM para modelar dependencias temporales en datos multisensor, complementadas con mecanismos de umbral adaptativo que ajustan dinámicamente la sensibilidad a las anomalías (Haque & Soliman, 2025). Este principio es directamente aplicable al monitoreo agroclimático: una arquitectura con capas LSTM puede aprender el patrón normal de enfriamiento nocturno en el altiplano y detectar

desviaciones que excedan los umbrales adaptativos configurados para cada región y cultivo.

2.3.2. Árboles de decisión y XGBoost

El eXtreme Gradient Boosting (XGBoost) es un algoritmo de aprendizaje supervisado basado en un ensamble de árboles de decisión que construye modelos de forma secuencial, donde cada nuevo árbol corrige los errores del anterior. Los marcos modernos de ML que integran XGBoost con detección de anomalías no supervisada explotan las fortalezas complementarias de ambos enfoques, logrando alto rendimiento predictivo al combinar la capacidad de XGBoost para modelar relaciones no lineales con la detección de patrones atípicos (Monteiro et al., 2025).

Su valor para el monitoreo agroclimático radica en tres características. Primera, su eficiencia computacional: XGBoost procesa grandes volúmenes de datos en paralelo, lo que lo hace viable para sistemas embebidos con recursos limitados. Segunda, su robustez frente a datos heterogéneos: los datasets de suelo y clima combinan variables de distinta naturaleza —temperatura, humedad, altitud, cobertura vegetal— que XGBoost maneja sin requerir normalización estricta. Tercera, su regularización integrada: minimiza una función de pérdida regularizada que penaliza la complejidad del modelo, lo cual es crítico cuando se trabaja con datos ruidosos provenientes de sensores IoT en campo, donde las lecturas erróneas o los valores atípicos por fallas de hardware son frecuentes.

En aplicaciones de monitoreo ambiental con redes de sensores inalámbricos, XGBoost actúa como clasificador supervisor que refina la detección de anomalías al diferenciar entre categorías específicas de eventos —como fallas de sensores versus intrusiones reales— con alta precisión

(Haque & Soliman, 2025). Trasladado al contexto agrícola, esta capacidad de clasificación fina permite distinguir entre una anomalía térmica real con riesgo de helada y una lectura aberrante por exposición solar directa al sensor, reduciendo las falsas alarmas que erosionan la confianza del productor en el sistema.

2.3.3. Modelos híbridos para predicción agroclimática

La tendencia actual en la detección de anomalías consiste en integrar arquitecturas híbridas que combinen las fortalezas de distintos algoritmos. Un ejemplo de este enfoque es el uso de un Autoencoder basado en Transformers para aprender el comportamiento normal de los sensores y detectar anomalías a partir de errores de reconstrucción, complementado con umbrales adaptativos que ajustan dinámicamente la sensibilidad según las tendencias recientes, Isolation Forest para la validación no supervisada de anomalías, y XGBoost como clasificador final que refina la categorización y diferencia entre tipos específicos de eventos. (Haque & Soliman, 2025).

En el ámbito del monitoreo ambiental con redes de sensores inalámbricos, este tipo de marco híbrido ha demostrado una precisión general del 95% en la clasificación de anomalías, con alta tasa de detección de intrusiones y reducción de falsos negativos, lo que evidencia su potencial para mejorar la confiabilidad de sistemas críticos de monitoreo ambiental (Haque & Soliman, 2025). Aplicado al contexto agroclimático del altiplano guatemalteco, este enfoque permitiría distinguir entre tres categorías de eventos en los datos de temperatura: lecturas normales dentro del rango esperado, fallas del sensor, y eventos climáticos extremos como heladas o inversiones térmicas que requieren alerta inmediata al productor.

2.4. Técnicas de detección de anomalías

2.4.1. Isolation Forest

El Isolation Forest (IF) es un algoritmo no supervisado que opera bajo un principio contrario al de la mayoría de los métodos de detección de anomalías: en lugar de modelar el comportamiento normal para luego identificar desviaciones, aísla directamente las observaciones anómalas. Las técnicas de aprendizaje automático convencionales como los métodos estadísticos y los sistemas basados en reglas son menos efectivos al trabajar con datos de alta dimensionalidad y no linealidad, limitación que Isolation Forest supera al identificar patrones novedosos sin requerir etiquetas de entrenamiento (Ahmad et al., 2025).

Su lógica de funcionamiento se basa en árboles de partición aleatoria: dado que las anomalías son pocas y distintas del comportamiento normal, se aíslan en menos divisiones del espacio de datos —es decir, requieren menor profundidad de árbol— que los puntos regulares. Isolation Forest ofrece escalabilidad para procesar y analizar datos extensos y de alta dimensionalidad sin requerir datos etiquetados en el entrenamiento, lo que lo hace ideal para el monitoreo en tiempo real en entornos variables (Monteiro et al., 2025). Para el monitoreo agroclimático en el altiplano occidental, estas propiedades son determinantes: los descensos térmicos abruptos asociados a heladas por radiación ocurren en ventanas de tiempo muy cortas —típicamente entre las 23:00 y las 07:00 horas— y deben detectarse en tiempo real para que la alerta sea accionable por el productor.

2.4.2. Z-Score y Modified Z-score

El Z-Score es una métrica estadística que cuantifica cuántas desviaciones estándar se aleja un dato de la media de su distribución:

$$Z = \frac{x - \mu}{\sigma}$$

Es el punto de partida más simple para la detección de anomalías en series de temperatura: un valor de $|z| > 3$ es convencionalmente señalado como outlier. Sin embargo, su eficacia depende de que los datos sigan una distribución aproximadamente normal, supuesto que con frecuencia no se cumple en datos climáticos con distribuciones asimétricas o con eventos extremos recurrentes.

Para estos casos, la literatura especializada recomienda el Modified Z-Score, que sustituye la media y la desviación estándar por la mediana y la desviación absoluta de la mediana (MAD, por sus siglas en inglés):

$$\tilde{z} = \frac{0.6745 * (x - \tilde{x})}{MAD}$$

donde $\tilde{x}$ es la mediana del conjunto y el factor 0.6745 corresponde al percentil 75 de la distribución normal estándar, que permite escalar el resultado de forma comparable al Z-Score clásico. El Modified Z-Score basado en MAD es considerado el método más rápido, simple y efectivo para la detección de outliers en muestras de tamaño pequeño en series temporales, precisamente porque MAD es menos sensible a los valores extremos que la desviación estándar, la cual depende del cuadrado de la desviación respecto a la media (Evtimov et al., 2023). En el monitoreo agroclimático del altiplano, donde los descensos de temperatura pueden ocurrir de forma abrupta y crear lecturas extremas que sesgarían la media histórica, el Modified Z-Score ofrece una línea

base estadística robusta y computacionalmente ligera, complementaria a los modelos de ML para la detección de anomalías en sensores IoT con recursos de procesamiento limitados.

2.5. Estado del arte de los sistemas de alerta temprana agroclimática

2.5.1. Sistemas internacionales de referencia

El desarrollo de sistemas de alerta temprana agroclimática no ocurre en el vacío: responde a un mandato global cada vez más urgente. La iniciativa "Early Warnings for All" (EW4All), lanzada en la COP27 de 2022 por el Secretario General de las Naciones Unidas, busca que toda persona en el planeta esté protegida por sistemas de alerta ante amenazas climáticas para finales de 2027, y está coliderada por la Organización Meteorológica Mundial (OMM) y la Oficina de las Naciones Unidas para la Reducción del Riesgo de Desastres (UNDRR), con el PNUMA como socio implementador (UNEP, 2022).

La justificación económica de esta inversión es contundente. Contar con tan solo 24 horas de anticipación ante un evento climático peligroso puede reducir los daños en un 30%, mientras que una inversión de 800 millones de dólares en sistemas de alerta multirisgo en países en desarrollo podría prevenir pérdidas anuales de entre 3 y 16 mil millones de dólares (UNEP, 2022). Sin embargo, solo la mitad de los países del mundo reporta capacidad para alertar a sus ciudadanos ante condiciones meteorológicas peligrosas, con cobertura inferior al 50% en los países menos desarrollados y apenas un tercio en los pequeños estados insulares (UNEP, 2022).

En América Latina, la articulación de estos principios con la realidad agrícola local ha tomado forma concreta. Paraguay, a través del Ministerio de

Agricultura y Ganadería, ha desarrollado Planes de Acciones Anticipatorias que vinculan los sistemas de monitoreo y alerta temprana con las Mesas Técnicas Agroclimáticas, estableciendo protocolos diferenciados por nivel de alerta para cultivos como maíz, sésamo, mandioca y caña de azúcar en la agricultura familiar

(Mayeregger, 2021). Este modelo de articulación —desde la alerta climática hasta la acción anticipatoria a nivel de parcela— constituye un referente directo para el diseño de sistemas similares en Guatemala.

2.5.2. Experiencias y referentes aplicables a Guatemala

Guatemala ha avanzado en convertir su sistema de Mesas Técnicas Agroclimáticas en un referente regional. En diciembre de 2025, una delegación del Ministerio de Desarrollo Agropecuario (MIDA) de Panamá y de la Secretaría Ejecutiva del Consejo Agropecuario Centroamericano (SECAC) visitó el altiplano occidental para conocer el modelo articulado entre el MAGA y el INSIVUMEH. El intercambio fue impulsado con el apoyo de la UICN en el marco del proyecto Altiplano Resiliente, con el objetivo de potenciar el impacto de las MTA en los territorios, especialmente con Pueblos Indígenas. Una de las prácticas más transferibles del modelo guatemalteco es la descentralización técnica del INSIVUMEH: la institución ha dado representatividad a sus sedes regionales y capacitado a su personal en la generación de productos climáticos que traducen la información meteorológica a lenguaje accesible para que las comunidades puedan tomar mejores decisiones de siembra y protección de cultivos (UICN, 2025).

En la dimensión técnica, los pronósticos mensuales del INSIVUMEH integran modelos dinámicos bajo la metodología NextGen junto con la normal climatológica 1991-2020, permitiendo comparar lo proyectado contra la línea base histórica por región y estación meteorológica para cada variable de

temperatura y precipitación (INSIVUMEH, 2025). Para el estado del ENOS, estos productos incorporan las predicciones del IRI con sus modelos dinámicos y estadísticos, reportando probabilidades diferenciadas por trimestre para La Niña, condiciones neutras y El Niño (INSIVUMEH, 2025), lo que permite a las MTA ajustar sus recomendaciones agrícolas según el escenario climático más probable.

Este modelo de articulación entre ciencia climática y acción comunitaria encuentra un paralelo en Paraguay, donde las Mesas Técnicas Agroclimáticas se han vinculado con los Planes de Acciones Anticipatorias, estableciendo protocolos que conectan el monitoreo de amenazas con respuestas concretas a nivel de parcela antes de que el evento ocurra (Mayeregger, 2021). Ambas experiencias apuntan en la misma dirección: los sistemas de alerta temprana son más efectivos cuando combinan modelos climáticos robustos con canales de comunicación que lleguen hasta el productor.

2.6. Descomposicion de serie temporales: tendencia, estacionalidad y residuo

Para que un modelo de detección de anomalías térmicas sea efectivo en el altiplano guatemalteco, debe ser capaz de distinguir entre lo que es esperado para una época del año —el ciclo de enfriamiento nocturno de diciembre, por ejemplo— y lo que constituye una desviación genuinamente anómala. Esta separación se logra mediante la descomposición de la serie temporal. La descomposición STL (*Seasonal-Trend decomposition using Loess*), propuesta por Cleveland et al. (1990), desglosa una serie temporal Y_t en tres componentes:

$$y_t = T_t + S_t + R_t$$

Donde T_t es la tendencia de largo plazo, S_t es el componente estacional y R_t es el residuo. La detección de anomalías se centra en el residuo: cuando ocurre un cambio en la estacionalidad o un evento extremo, este se manifiesta como un punto de spike en el residuo descompuesto R_t , lo que permite monitorearlo de forma independiente del comportamiento esperado (He et al., 2023). En datos de temperatura del altiplano occidental, T_t captura el calentamiento progresivo documentado por el INSIVUMEH, S_t absorbe el ciclo anual de lluvias y temperatura, y R_t concentra los eventos extremos como heladas por radiación o descensos abruptos asociados a frentes fríos.

STL opera mediante la aplicación iterativa del suavizador LOESS: estima primero el componente estacional, lo sustrae de la serie original, y aplica nuevamente LOESS para obtener la tendencia; el residuo es lo que queda tras restar ambos componentes (He et al., 2023). Su diseño simple permite un cómputo eficiente incluso con series largas, lo que lo hace viable para sistemas de monitoreo IoT que generan lecturas continuas a intervalos de minutos.

2.7. Arquitectura IoT y protocolos de comunicación para agricultura de precisión

2.7.1. Arquitectura por capas: percepción, red, nube y aplicación

Un sistema IoT para el agro se organiza en capas funcionales que permiten que los datos fluyan desde el campo hasta la decisión del productor de forma estructurada. La arquitectura IoT en agricultura puede dividirse en una capa de percepción para el reconocimiento y captura de datos, una capa de red para la transmisión y recepción, y una capa de aplicación para los servicios agrícolas específicos; en la capa de percepción, los nodos de sensores se instalan en diversas áreas —cultivos, ganadería, maquinaria agrícola— para capturar parámetros en tiempo real, y los datos se transmiten al gateway local

(Friha et al., 2021). En implementaciones modernas, entre la red y la aplicación se inserta una capa de nube o procesamiento analítico donde se almacenan las series históricas y se ejecutan los modelos de ML.

Las cuatro capas y su función en un sistema de alerta agroclimática son las siguientes. La capa de percepción contiene los sensores que miden temperatura, humedad relativa, humedad del suelo y precipitación directamente en la parcela. La capa de red incluye los nodos, gateways y protocolos de comunicación —como LoRaWAN— que transportan los datos desde el campo hasta la infraestructura de procesamiento. La capa de nube/datos almacena las series temporales y ejecuta los algoritmos de detección de anomalías (LSTM, Isolation Forest, STL). La capa de aplicación entrega las alertas al productor a través de interfaces accesibles —SMS, aplicación móvil o panel web— en el momento oportuno para tomar decisiones de siembra o protección de cultivos.

El IoT agrícola ha evolucionado para incorporar tecnologías emergentes como vehículos aéreos no tripulados, plataformas abiertas, computación en la nube y en el borde, y plataformas de middleware, clasificando sus aplicaciones en categorías que incluyen monitoreo inteligente, gestión del agua, aplicación de agroquímicos, gestión de enfermedades, cosecha inteligente y gestión de la cadena de suministro (Friha et al., 2021). Para el contexto del Altiplano Occidental guatemalteco, la capa más crítica es la de red, dado que las zonas rurales de alta montaña presentan cobertura celular limitada, lo que hace de LoRaWAN la tecnología más viable para garantizar conectividad en áreas remotas con topografía accidentada.

2.7.2. Protocolo MQTT y modelo publish-subscribe

MQTT (*Message Queuing Telemetry Transport*) es un protocolo ligero de mensajería diseñado específicamente para dispositivos con recursos computacionales limitados y redes de baja calidad o alto costo de ancho de

banda. Su arquitectura se basa en un modelo de publicación-suscripción (*publish-subscribe*) mediado por un broker: los sensores publican sus lecturas en un tópico y los sistemas suscriptores —plataformas de análisis, dashboards, motores de alerta— reciben esos datos de forma asíncrona sin que exista una conexión directa entre emisor y receptor. Entre las tecnologías emergentes para el IoT agrícola se incluyen plataformas de middleware que permiten integrar diversas fuentes de datos y formatos, facilitando la interoperabilidad entre los nodos de sensores en campo y los sistemas de procesamiento analítico en la nube (Friha et al., 2021). MQTT opera precisamente en esta capa de middleware: al reducir drásticamente el overhead de las comunicaciones respecto a protocolos como HTTP, disminuye tanto el uso de ancho de banda como el consumo energético, factores críticos para sensores alimentados por baterías desplegados en zonas remotas del altiplano guatemalteco.

La arquitectura LoRaWAN para monitoreo ambiental en agricultura inteligente se construye sobre una red de sensores de bajo costo y largo alcance que recolectan parámetros como temperatura y humedad, con los datos transmitidos al gateway local y posteriormente enviados a plataformas en la nube para su análisis y visualización (Prasetya et al., 2022). En implementaciones típicas, MQTT actúa como el protocolo de transporte entre el gateway LoRaWAN y el servidor de aplicaciones, combinando así las ventajas de cobertura de LoRaWAN con la eficiencia de mensajería de MQTT en una arquitectura de extremo a extremo viable para entornos rurales con conectividad limitada.

2.7.3. LoRaWAN y redes LPWAN para zonas rurales

LoRaWAN (*Long Range Wide Area Network*) es la tecnología LPWAN (*Low Power Wide Area Network*) con mayor adopción en aplicaciones de

agricultura inteligente, particularmente en entornos rurales donde la cobertura celular es limitada o inexistente. LoRaWAN es un protocolo de comunicación diseñado específicamente para aplicaciones IoT que ofrece ventajas de conexión a larga distancia y bajo consumo de energía, y ha ganado gran popularidad en monitoreo ambiental, agricultura inteligente y salud, entre otras aplicaciones (Augustin et al., 2023).

Su ventaja frente a tecnologías como WiFi o ZigBee se basa en tres características complementarias. Primera, el **largo alcance**: la implementación de protocolos de control de tasa adaptativa y verificación de errores permite que los gateways LoRaWAN transmitan datos de forma confiable a más de 15 km en aplicaciones rurales y semiurbanas, con una tasa de pérdida de paquetes inferior al 0.1% (Aldhaferi et al., 2024).

Segunda, la **autonomía energética**: los nodos operados con batería pueden mantenerse activos durante años sin intervención, lo que es esencial en parcelas de difícil acceso. Tercera, la **operación en bandas no licenciadas**: LoRaWAN no requiere concesión de espectro, lo que elimina costos recurrentes de operación.

Lo más relevante para el contexto del Altiplano Occidental guatemalteco es la evidencia de su funcionamiento en entornos de alta montaña. Un sistema IoT basado en LoRaWAN para agricultura en zonas alto-andinas, desplegado a 3,800 metros sobre el nivel del mar, logró comunicaciones estables a 5 km y 10 km con una tasa de transmisión exitosa del 100%, con nodos alimentados por energía solar, demostrando que LoRaWAN puede superar las barreras de conectividad en entornos rurales de alta altitud y ofrecer una solución escalable que fortalece la resiliencia climática y optimiza las prácticas agrícolas (Autores, 2025). En el ámbito del smart farming con redes LoRaWAN, los dispositivos IoT

permiten al productor acceder a lecturas en tiempo real para la toma de decisiones, con la capacidad de llegar incluso a las fincas más remotas dentro de la red de monitoreo y control (IEEE, 2024).

2.7.4. Comparacion con otras tecnologías de comunicacion

La elección de la tecnología de comunicación para un sistema IoT agroclimático no es trivial: cada protocolo implica compromisos distintos entre alcance, consumo energético y costo de despliegue. Una evaluación empírica del consumo energético de las principales tecnologías LPWAN —LoRaWAN, Sigfox y NB-IoT— determinó que LoRaWAN y DASH7 son más eficientes energéticamente que Sigfox y NB-IoT, con un estudio de caso específico en agricultura de precisión en invernadero que mostró que la vida útil de la batería en aplicaciones reales puede caer significativamente respecto al caso ideal (Mekki et al., 2020).

Tabla X Comparación de tecnologías de comunicación inalámbrica para sistemas IoT agrícolas

Tecnología	Alcance	Consumo de Energía	Costo de Despliegue
LoRaWAN	Muy Alto (hasta 15 km)	Muy Bajo	Bajo
WiFi	Bajo (≈100 m)	Alto	Medio
Sigfox	Muy Alto	Muy Bajo	Alto (suscripción)
NB-IoT	Medio/Alto	Medio	Medio (operador)

Nota. Elaboración propia basada en Mekki et al. (2020) y Augustin et al. (2023).

Sigfox, LoRaWAN y NB-IoT presentan ventajas y desventajas que se manifiestan en distintos escenarios: Sigfox es más confiable para paquetes cortos transmitidos en modo no confirmado; LoRaWAN supera a las demás tecnologías cuando los sensores transmiten paquetes largos de forma no confirmada; mientras que NB-IoT demuestra mayor confiabilidad cuando los sensores transmiten paquetes cortos en modo de reconocimiento (Blinnikov et al., 2022). Para el monitoreo agroclimático en el Altiplano Occidental, donde los sensores envían lecturas periódicas de temperatura y humedad —paquetes pequeños a intervalos regulares— y operan en zonas sin cobertura celular confiable, LoRaWAN ofrece la combinación óptima de alcance, autonomía energética y costo de despliegue sin dependencia de operadores de red.

2.7.5. Edge computing y fog computing en monitoreo Agrícola

El procesamiento distribuido resuelve uno de los principales cuellos de botella de los sistemas IoT agrícolas en zonas rurales: la dependencia de conectividad constante con la nube. El edge computing opera en nodos locales cercanos a las fuentes de datos —gateways agrícolas, servidores de borde y terminales embarcados en maquinaria— y sus principales fortalezas son la baja latencia, la capacidad de respuesta en tiempo real y la eficiencia de ancho de banda, lo que lo hace especialmente efectivo en escenarios que requieren procesamiento inmediato y toma de decisiones localizada, como el manejo autónomo de ambientes en invernadero y el control de riego responsivo basado en condiciones de campo (Tripathy et al., 2025). En un sistema de alerta temprana para heladas, esto significa que el gateway puede disparar una alerta al productor en segundos tras detectar una caída crítica de temperatura, sin esperar el ciclo de transmisión a la nube y de vuelta.

El fog computing actúa como capa intermedia entre los dispositivos en campo y la plataforma cloud. Estrategias de descarga computacional de la nube hacia la capa fog permiten procesar un mayor número de tareas de aprendizaje profundo en cada nodo fog, con el objetivo de reducir el volumen de datos transferidos a la nube, utilizar los recursos de forma eficiente y disminuir la congestión de red (Hussain et al., 2023). Aplicado al monitoreo del altiplano guatemalteco, el gateway LoRaWAN puede operar como nodo fog que agrega y pre-procesa lecturas de temperatura de múltiples sensores distribuidos en distintas parcelas, ejecutando el Modified Z-Score o Isolation Forest localmente antes de enviar únicamente los eventos anómalos —no el flujo completo de datos— a la plataforma cloud.

La aplicación más directa al problema de heladas agrícolas está documentada explícitamente en la literatura. Se ha propuesto una plataforma basada en edge computing para la identificación temprana de heladas en cultivos, estimando temperaturas bajas mediante un modelo LSTM ejecutado directamente en dispositivos de borde, lo que permite al agricultor obtener predicciones de temperatura en tiempo real bajo restricciones de conectividad de bajo ancho de banda y consumo energético (Hussain et al., 2023). Esta arquitectura edge-fog-cloud constituye el referente técnico más cercano al sistema propuesto en esta tesis para el Altiplano Occidental de Guatemala.

2.8. Arquitectura de sistemas de soporte a decisiones y visualización de alertas

Un Sistema de Soporte a las Decisiones (DSS, por sus siglas en inglés) va más allá del almacenamiento y visualización de datos: su función central es traducir lecturas de sensores en recomendaciones accionables para el productor. Los DSS en agricultura integran datos de múltiples fuentes con la

meta última de proveer a los usuarios finales perspectivas que apoyen su proceso crítico de toma de decisiones; a medida que estas plataformas escalan hacia sistemas de monitoreo en tiempo real con grandes volúmenes de datos, sus objetivos se vuelven más desafiantes por la sobrecarga de información y los requerimientos de diseño centrado en el usuario (Gutiérrez et al., 2022).

La visualización es el componente que determina si la información técnica llega efectivamente al productor. Los DSS agrícolas visuales se evalúan en términos de usabilidad, carga cognitiva, aceptación y confianza; los resultados muestran que los sistemas web basados en dashboards son percibidos como altamente funcionales por los usuarios, aunque requieren un balance cuidadoso entre demanda mental y facilidad de uso (Gutiérrez et al., 2022). Para el contexto del Altiplano Occidental guatemalteco, donde los usuarios finales incluyen tanto técnicos del MAGA con experiencia analítica como agricultores de subsistencia con acceso limitado a tecnología, el diseño de la interfaz debe priorizar la simplicidad: semáforos de riesgo (verde/amarillo/rojo) y mensajes de alerta en idioma local resultan más efectivos que gráficas de series temporales complejas. Los mensajes entregados por un sistema de alerta temprana deben diseñarse para que su contenido y formato produzcan información accionable y utilizable para la comunidad agrícola; estudios en contextos de pequeños productores en África Oriental identificaron que el interés es alto en sistemas que combinen mapas interactivos de distribución de riesgos con recomendaciones de manejo concretas (Allen-Sader et al., 2022). Este principio —pasar de datos a conocimiento accionable— es la brecha que un DSS bien diseñado debe cerrar: cuando el sistema detecta una anomalía de temperatura consistente con riesgo de helada, no debe limitarse a mostrar el dato numérico, sino sugerir medidas preventivas específicas como el riego de defensa o el uso de coberturas térmicas, calibradas según la fase fenológica del cultivo predominante en esa parcela.

2.9. Consideraciones éticas y de privacidad de datos agroclimáticos

La digitalización del campo no es un proceso éticamente neutro. A medida que los sistemas IoT agrícolas recopilan lecturas continuas de temperatura, humedad y prácticas de manejo en parcelas individuales, emerge una pregunta fundamental: ¿quién es el propietario legítimo de esos datos y quién se beneficia de ellos?

La ausencia de un marco legal universal que defina la propiedad de los datos en agricultura crea ambigüedades sobre los derechos de acceso, modificación y distribución; estudios indican que muchos contratos de tecnología agrícola otorgan un control extensivo sobre los datos de la finca a los proveedores de tecnología, con frecuencia sin que los agricultores comprendan plenamente las implicaciones. (Kher, 2025).

Este riesgo se materializa de formas concretas: empresas en el Cinturón Maicero de Estados Unidos han vendido estimaciones tempranas de rendimiento derivadas de datos de agricultores a operadores de commodities, obteniendo beneficios comerciales sin compensación ni consentimiento de los productores (Kher, 2025).

En respuesta a estos vacíos regulatorios, han surgido iniciativas de gobernanza voluntaria. La iniciativa Ag Data Transparent, impulsada por la American Farm Bureau Federation, establece principios que incluyen la propiedad del agricultor sobre sus datos, transparencia en la recolección, seguridad robusta y divulgación clara en los acuerdos de intercambio de datos (Kher, 2025). En paralelo, los principios de ética de datos por diseño plantean que las consideraciones éticas —privacidad, equidad, transparencia y rendición

de cuentas— deben integrarse proactivamente en todo el ciclo de vida de la gestión de datos desde su concepción, y no como una corrección posterior; esto es particularmente crítico en agricultura, donde la confianza es el fundamento de las relaciones comerciales (AgGateway, 2025).

Para el contexto guatemalteco, estas consideraciones adquieren una dimensión adicional de vulnerabilidad. Los pequeños productores del Altiplano Occidental —muchos de ellos pertenecientes a comunidades indígenas— carecen de las herramientas de literacidad digital necesarias para comprender acuerdos de servicios complejos o ejercer sus derechos sobre los datos que generan. Las mejores prácticas de gobernanza de datos agrícolas incluyen definir claramente los derechos de propiedad del originador de los datos, garantizar su pleno control sobre la recolección, uso y eliminación, obtener consentimiento informado antes de cualquier recolección o compartición, y reducir la brecha digital mejorando el acceso a programas de literacidad en datos e infraestructura digital (AgGateway, 2025). Un sistema de alerta temprana agroclimática diseñado para el altiplano guatemalteco debe, por tanto, incorporar estos principios desde su arquitectura: datos anonimizados, sin transferencia a terceros comerciales, con propiedad comunitaria de la información generada en cada parcela.

3. METODOLOGIA Y PROCESAMIENTO DE DATOS


3.1. Enfoque metodológico de la investigación

La investigación se plantea con un enfoque aplicado y cuantitativo, porque usa datos climáticos, agrícolas y de suelo para desarrollar un prototipo funcional de apoyo a la decisión agroclimática. El trabajo no se queda solo en el análisis teórico, sino que construye una plataforma web que permite consultar información, ejecutar predicciones de rendimiento, revisar alertas y visualizar resultados por cultivo y municipio.

El prototipo AgroClima GT se valida principalmente desde el punto de vista técnico y funcional. Esto significa que se revisa si el sistema puede cargar datos, procesarlos, ejecutar el modelo predictivo, guardar resultados y mostrarlos en la interfaz web. No se debe presentar todavía como una validación final en campo, porque la parte física con sensores no ha sido comprobada en parcelas reales.

El sistema implementado combina un backend en FastAPI, un frontend en React/Vite, una base de datos PostgreSQL, archivos locales de datos, un modelo XGBoost para estimar rendimiento agrícola y un módulo de detección de anomalías con Isolation Forest. También incluye soporte para Arduino por puerto serial y simulación de lecturas, pero esto debe describirse como integración técnica inicial, no como red IoT desplegada.

Figura 1. *Flujo metodológico del prototipo AgroClima GT*



Referencia APA de la figura: Elaboración propia. (2026). **Flujo metodológico del prototipo AgroClima GT** [Diagrama]. Tesis de prototipo AgroClima GT.

3.2. Adquisición y procesamiento del dataset ERA5-land

El dataset climático base se construye a partir de ERA5-Land, una fuente de reanálisis que permite trabajar con variables terrestres y climáticas de forma consistente. ERA5-Land es útil porque ofrece una base histórica amplia para analizar temperatura, lluvia, humedad y otras variables relacionadas con condiciones agroclimáticas (Muñoz-Sabater et al., 2021).

En el prototipo, ERA5-Land no se usa de forma aislada. La información se complementa con datos de NASA POWER, SoilGrids, Open-Meteo e INSIVUMEH procesado localmente. Esta combinación permite que el sistema no dependa de una sola fuente y que el dataset final tenga variables climáticas, edáficas y agrícolas.

El archivo principal del prototipo es dataset_v2.csv, que contiene registros por cultivo, municipio, año, mes y variables ambientales. Este archivo se usa para entrenar y evaluar el modelo de rendimiento. Por eso, en la tesis

debe decirse que el dataset es una construcción procesada del proyecto, no una descarga directa sin transformación.

Tabla 1. *Archivos climáticos y agrícolas usados por el prototipo*

Archivo	Ubicación en el proyecto	Uso dentro del prototipo
dataset_v2.csv	backend/data/datasets/	Dataset principal para entrenamiento y evaluación del modelo de rendimiento.
era5_mensual.csv	backend/data/sources/	Base climática histórica mensual por municipio.
nasa_power_mensual.csv	backend/data/sources/	Variables complementarias como radiación, temperatura máxima, temperatura mínima y viento.
soilgrids_suelo.csv	backend/data/sources/	Propiedades de suelo, principalmente pH y variables edáficas.
insivumeh_recent_mensual.csv	backend/data/sources/	Datos recientes procesados de INSIVUMEH.
water_stress_index.csv	backend/data/processed/	Índice de estrés hídrico por municipio, año y mes.
sowing_calendar.csv	backend/data/processed/	Calendario agrícola usado como apoyo por cultivo y municipio.

Elaboración propia. (2026). **Archivos climáticos y agrícolas usados por AgroClima GT** [Tabla]. Prototipo AgroClima GT.

3.2.1. Fuentes de datos climáticos: estaciones INSIVUMEH y ERA5-Land

Las fuentes climáticas usadas en el prototipo se organizan en dos grupos. El primer grupo corresponde a datos históricos y procesados

localmente, donde se incluye ERA5-Land e información climática del INSIVUMEH disponible en archivos diarios o mensuales dentro del proyecto. El segundo grupo corresponde a fuentes complementarias que apoyan el modelo y las consultas de la interfaz, como NASA POWER, SoilGrids y Open-Meteo.

ERA5-Land se utiliza como base climática histórica porque ofrece cobertura espacial y temporal amplia. INSIVUMEH se usa como referencia nacional procesada, pero no debe escribirse que existe una conexión oficial en tiempo real si el sistema solo consume archivos ya preparados. Open-Meteo se usa para pronóstico meteorológico desde la API, NASA POWER aporta variables complementarias como radiación y viento, y SoilGrids aporta información de suelo como pH y otras propiedades edáficas.

Tabla 2. *Fuentes de datos integradas en AgroClima GT.*

Fuente	Variables principales	Archivo o módulo	Uso dentro del sistema
ERA5-Land	Temperatura, lluvia, humedad, humedad de suelo y temperatura de suelo	<code>era5_mensual.csv</code>	Base climática histórica del dataset.
INSIVUMEH	Temperatura, lluvia, humedad, temperatura mínima, temperatura máxima y viento	<code>insivumeh_recent_mensual.csv</code>	Referencia nacional procesada para datos recientes.
NASA POWER	Radiación solar, lluvia, humedad, temperatura máxima, temperatura mínima y viento	<code>nasa_power_mensual.csv</code>	Variables climáticas complementarias.
SoilGrids	pH, carbono orgánico, textura, densidad aparente y nitrógeno	<code>soilgrids_suelo.csv</code>	Características edáficas por municipio.
Open-Meteo	Pronóstico meteorológico	<code>API consultada desde backend</code>	Pronóstico de 7 días y apoyo a formularios.
Arduino local	Temperatura, luz, humedad de suelo y color/pH según diseño	<code>backend/arduino_reader.py</code>	Lecturas por USB o simulación para pruebas.

Elaboración propia. (2026). **Fuentes de datos integradas en AgroClima GT** [Tabla]. Tesis de prototipo AgroClima GT.

3.2.2. Descarga, limpieza, y normalización de datos

El procesamiento de datos en AgroClima GT convierte fuentes heterogéneas en una estructura tabular común. Los archivos climáticos, agrícolas y de suelo se organizan por municipio, cultivo, mes y año. Durante la limpieza se revisan columnas, formatos, valores faltantes y rangos razonables para que las variables sean consistentes antes de alimentar el modelo.

La preparación de datos incluye la codificación de variables categóricas como municipio y cultivo, además de la revisión de variables numéricas como temperatura, lluvia, humedad, pH, humedad del suelo, luz y viento. En esta versión del prototipo, el modelo principal es XGBoost, por lo que el flujo se concentra en consistencia tabular, validación de rangos y codificación de entradas.

Tabla 3. *Muestra del dataset tabular usado para entrenamiento.*

municipio	crop	month	year	temperatu re	rainfall	humidity	soil moistu re	soil_ph	light_lux	temp_max	temp_min	wind spee d	yield_pct
Cahabon	Naranja	1	2024	20.69	141.7	85.5	0.3372	5.73	39656.0	33.05	12.60	0.87	97.6
San Marcos	Soya	3	2024	15.69	17.2	69.6	0.1774	5.53	56425.0	30.01	13.26	0.83	75.1

Elaboración propia. (2026). **Muestra del dataset tabular usado para entrenamiento** [Tabla]. Prototipo AgroClima GT.

3.2.3. Validacion de ERA5-Land con datos observados

La validación de ERA5-Land se aborda como una revisión de coherencia con datos nacionales procesados. ERA5-Land aporta una base histórica de

reanálisis, mientras que INSIVUMEH sirve como referencia nacional reciente dentro del proyecto. Esta comparación permite revisar tendencias y rangos generales, aunque no constituye una validación estadística oficial por estación.

Una validación formal requeriría comparar valores de ERA5-Land contra registros observados por estación, periodo y ubicación, calculando métricas como sesgo, correlación, MAE o RMSE. En el alcance actual, AgroClima GT usa INSIVUMEH como apoyo local y mantiene ERA5-Land como fuente climática histórica principal.

Tabla 4. Alcance de validación entre ERA5-Land e INSIVUMEH.

Elemento	Estado en el prototipo	Uso
ERA5-Land	Fuente histórica procesada	Base climática principal.
INSIVUMEH	Fuente reciente procesada	Referencia nacional complementaria.
Comparación estadística por estación	No consolidada como resultado final	Línea futura de validación.
Evaluación actual	Revisión de coherencia	Validación preliminar del dataset.

Elaboración propia. (2026). *Alcance de validación entre ERA5-Land e INSIVUMEH* [Tabla]. Tesis de prototipo AgroClima GT.

3.3. Tratamiento de datos y limpieza de series temporales

El tratamiento de datos se centra en preparar registros mensuales organizados por municipio, cultivo y año. Aunque las fuentes climáticas tienen naturaleza temporal, el prototipo trabaja principalmente con datos tabulares

derivados de esa información. Esta estructura permite usar variables climáticas, de suelo y de cultivo como entradas del modelo predictivo.

La limpieza de series se traduce en revisión de consistencia, alineación de columnas, control de rangos y preparación de registros para análisis mensual. El enfoque se ajusta al uso de XGBoost, que permite trabajar con múltiples variables tabulares sin depender de una serie univariada de temperatura.

3.3.1. Integración de datos históricos y datos en tiempo real

La integración de datos se divide en dos grupos. El primero corresponde a datos históricos y procesados, que alimentan el dataset y el modelo. El segundo corresponde a datos en tiempo real o simulados, recibidos desde el módulo Arduino por puerto serial o generados desde la interfaz para validar el flujo de sensores.

La versión actual del prototipo integra sensores mediante conexión local y simulación. Las lecturas se envían al backend y pueden visualizarse en la interfaz mediante WebSocket. Esta integración permite probar el flujo operativo antes de realizar una instalación física de sensores en campo.

Tabla 5. *Tipos de datos integrados en el prototipo.*

Tipo de dato	Fuente	Estado
Histórico climático	ERA5-Land, NASA POWER, INSIVUMEH	Implementado en archivos locales.
Suelo	SoilGrids	Implementado en archivos locales.
Pronóstico	Open-Meteo	Consultado desde backend.
Sensores	Arduino USB o simulación	Implementado a nivel de software.
Campo real	Sensores instalados en parcelas	Etapas posteriores de validación.

Tabla 6. *Elaboración propia. (2026). Tipos de datos integrados en AgroClima GT [Tabla]. Tesis de prototipo AgroClima GT.*

3.3.2. Alineación temporal y espacial de registro

La alineación temporal se realiza mediante registros organizados por año y mes. Esta escala permite relacionar condiciones climáticas con rendimiento agrícola sin exigir una frecuencia horaria para todo el dataset. La alineación espacial se maneja a nivel de municipio, que es la unidad usada por el dataset, el formulario de predicción y el mapa de riesgo.

Cuando se usa Arduino o simulación, la lectura queda asociada al municipio y cultivo configurado por el usuario. Esto ubica la lectura dentro del contexto del análisis, aunque no representa todavía una georreferenciación exacta por parcela.

3.3.3. Tratamiento de valores faltantes e inconsistencias

Los valores faltantes e inconsistentes se tratan mediante revisión de datos procesados y validación de entradas. El backend verifica rangos de variables como temperatura, lluvia, humedad, pH, humedad del suelo y luz antes de ejecutar predicciones. Esta validación reduce resultados incoherentes y evita que el modelo reciba valores fuera de rangos plausibles.

El prototipo maneja la calidad de datos desde una perspectiva práctica: archivos procesados, validación de formularios, control de rangos y manejo de errores de fuentes externas. La imputación espacial avanzada y la interpolación detallada quedan fuera del flujo implementado.

3.4. Ingeniería de características para el modelo predictivo

La ingeniería de características transforma datos climáticos, edáficos y agrícolas en variables útiles para el modelo. El dataset incluye municipio, cultivo, mes, año, temperatura, lluvia, humedad, humedad del suelo, temperatura del suelo, pH, luz estimada, índice de verdor, temperatura máxima, temperatura mínima, viento y rendimiento estimado.

Las variables categóricas se codifican mediante archivos Joblib, mientras que las variables numéricas representan condiciones ambientales y agronómicas. Esta combinación permite que XGBoost estime el rendimiento agrícola esperado para un cultivo y municipio determinados.

Tabla 7. *Variables del modelo y fundamento agroclimático.*

Variable	Fundamento
Municipio	Ubicación y contexto climático.
Cultivo	Diferencias de respuesta ante clima y suelo.
Mes y año	Temporalidad agrícola y estacionalidad.
Temperatura mínima y máxima	Estrés térmico.
Lluvia y humedad	Disponibilidad hídrica.
Humedad de suelo y pH	Condición edáfica.
Luz e índice de verdor	Condición de crecimiento vegetal.

Elaboración propia. (2026). **Variables del modelo y fundamento agroclimático** [Tabla]. Tesis de prototipo AgroClima GT.

3.4.1. Horas frío, estrés térmico y variables derivadas

En AgroClima GT, el análisis de estrés térmico se representa mediante temperatura mínima, temperatura máxima y temperatura media. El prototipo no calcula horas frío como variable central, pero sí utiliza variables que permiten aproximar condiciones de frío, calor y estrés ambiental para los cultivos.

Las variables derivadas se complementan con archivos de apoyo agronómico. `crop_optimal_conditions.csv` define rangos óptimos por cultivo; `water_stress_index.csv` resume estrés hídrico por municipio, año y mes;

recommendations.csv contiene recomendaciones según condición y severidad; y sowing_calendar.csv relaciona cultivos con meses más favorables.

Tabla 8. *Variables derivadas y apoyo agronómico.*

Archivo	Aporte al análisis
crop_optimal_conditions.csv	Rangos óptimos por cultivo.
water_stress_index.csv	Estrés hídrico por municipio, año y mes.
recommendations.csv	Recomendaciones por variable y severidad.
sowing_calendar.csv	Meses favorables por cultivo y municipio.

Elaboración propia. (2026). **Variables derivadas y apoyo agronómico en AgroClima GT** [Tabla]. Tesis de prototipo AgroClima GT.

3.4.2. Incorporación de fases fenológicas como variables predictoras

Las fases fenológicas explican que un cultivo no responde igual al clima durante todo su desarrollo. En el prototipo, esta relación se aproxima mediante cultivo, mes y calendario agrícola. El mes funciona como una variable temporal que ayuda a representar estacionalidad, mientras que el cultivo permite diferenciar sensibilidad a temperatura, lluvia, humedad y suelo.


El archivo sowing_calendar.csv aporta una forma práctica de relacionar municipio, cultivo y mes con periodos de mejor rendimiento. Así, la fenología se incorpora de manera indirecta, usando calendario agrícola y temporalidad mensual como variables de apoyo para el análisis predictivo.

3.4.3. Decomposicion STL y transformación de series

La descomposición STL se mantiene como antecedente teórico para análisis de series temporales, pero el flujo implementado en AgroClima GT usa una estrategia tabular y detección de anomalías con Isolation Forest. Las series climáticas se transforman en registros mensuales por municipio, cultivo y año, lo cual permite integrarlas con variables de suelo y cultivo.

Isolation Forest identifica observaciones atípicas mediante particiones aleatorias y apoya la detección de entradas o lecturas fuera del comportamiento esperado (Liu et al., 2008; scikit-learn Developers, s.f.). Esta adaptación corresponde al prototipo actual, donde la detección de anomalías se aplica como apoyo funcional para lecturas o condiciones inusuales.

Tabla 9. *Flujo adaptado de detección de anomalías.*



Elaboración propia. (2026). **Flujo adaptado de detección de anomalías en AgroClima GT** [Diagrama]. Tesis de prototipo AgroClima GT.

3.5. Estrategia de entrenamiento, validación y ajuste de modelos

El entrenamiento del modelo se realiza con XGBoost para estimar yield_pct. Esta técnica es adecuada para datos tabulares porque trabaja con variables numéricas y categóricas codificadas, además de manejar relaciones no lineales entre clima, suelo, cultivo y rendimiento (XGBoost Developers, s.f.).

El modelo entrenado se guarda como xgboost_yield.joblib y los codificadores se almacenan en `label\_encoders.joblib`. La comparación interna del prototipo muestra mejor desempeño de XGBoost frente a Random Forest, por lo que se utiliza como modelo principal.

Tabla 10. Comparación interna de modelos.

Modelo	R ²	MAE	RMSE	Tiempo
XGBoost	0.7157	4.86	6.04	3.4 s
Random Forest	0.4485	6.84	8.42	5.4 s

Elaboración propia. (2026). *Comparación interna de modelos en AgroClima GT* [Tabla]. Tesis de prototipo AgroClima GT.

3.6. Métricas de evaluación y validación de modelos

La evaluación del prototipo se organiza según el tipo de salida. Para rendimiento agrícola se usan métricas de regresión porque el modelo estima un

valor numérico. Para anomalías y alertas se realiza validación funcional mediante escenarios controlados, ya que aún no existe un conjunto de eventos reales etiquetados.

Esta separación permite presentar resultados disponibles sin mezclar métricas de naturaleza distinta. La regresión se evalúa con R^2 , MAE y RMSE; la clasificación de anomalías queda como una etapa futura cuando se cuente con eventos confirmados de campo.

3.6.1. Métricas de regresión: $RMSE$, MAE , y R^2

La evaluación del componente de predicción de temperatura mínima requiere métricas que cuantifiquen el error en las mismas unidades que la variable objetivo —grados Celsius— para que los resultados sean interpretables por técnicos agroclimáticos sin formación estadística avanzada. El RMSE (*Root Mean Square Error*) es la métrica principal para la predicción de temperatura mínima:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2}$$

Su propiedad de penalizar los errores grandes cuadráticamente la hace especialmente adecuada para este contexto: un error de pronóstico de 3°C cuando la temperatura real es 1°C significa una helada no detectada y pérdida total del cultivo, mientras que el mismo error en sentido positivo solo genera una alerta innecesaria. RMSE captura esta asimetría de consecuencias al magnificar los errores extremos.

El MAE (*Mean Absolute Error*) complementa al RMSE como medida robusta ante valores atípicos:

$$MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$$

Mientras que RMSE es sensible a los errores grandes, MAE refleja el error promedio típico en condiciones normales de operación. Reportar ambas métricas permite distinguir si el modelo falla sistemáticamente (MAE alto) o solo en eventos extremos (RMSE alto con MAE bajo).

RMSE, MAE y R^2 permiten medir el desempeño del modelo de rendimiento. El MAE muestra el error promedio absoluto, el RMSE penaliza con mayor fuerza los errores grandes y el R^2 resume la proporción de variabilidad explicada por el modelo. En la comparación interna, XGBoost obtuvo R^2 de 0.7157, MAE de 4.86 y RMSE de 6.04.

Tabla 11. *Métricas principales del modelo XGBoost.*

Métrica	Valor	Interpretación
R^2	0.7157	Capacidad explicativa sobre el dataset.
MAE	4.86	Error absoluto medio.
RMSE	6.04	Error con penalización a desviaciones grandes.

Elaboración propia. (2026). **Métricas principales del modelo XGBoost** [Tabla]. Tesis de prototipo AgroClima GT.

3.6.2. Métricas de clasificación: Presicion, Recall y F1-Score

Las métricas de clasificación se asocian con la validación de alertas y anomalías. Precisión, recall, F1-Score y matriz de confusión requieren eventos etiquetados como normales o anómalos. En AgroClima GT, la etapa actual trabaja con validación funcional, por lo que estas métricas se reservan para pruebas posteriores con datos reales confirmados.

La validación funcional verifica que el sistema genere alertas ante entradas fuera de rango, lecturas simuladas anómalas o predicciones de bajo rendimiento. Este enfoque comprueba la lógica operativa del prototipo antes de avanzar hacia una evaluación estadística de clasificación.


4. DISEÑO E IMPLEMENTACION DEL PROTOTIPO

4.1. Arquitectura general del sistema predictivo

AgroClima GT se organiza como una arquitectura modular. El frontend en React/Vite permite la interacción con el usuario, el backend en FastAPI recibe solicitudes y ejecuta la lógica principal, PostgreSQL almacena información operativa y los archivos locales guardan datasets, modelos, codificadores y métricas. El sistema también integra Open-Meteo para pronóstico y Arduino por USB o simulación para lecturas de sensores.


La arquitectura separa la presentación, el procesamiento, la persistencia y el análisis predictivo. Esta división facilita el mantenimiento del prototipo y permite escalarlo posteriormente hacia un despliegue más formal.

Figura 2. *Casos de uso de alto nivel del prototipo AgroClima GT.*




Elaboración propia. (2026). *Casos de uso de alto nivel del prototipo AgroClima GT* [Diagrama PlantUML].

Figura 3. *Primera descomposición de casos de uso del sistema AgroClima GT.*




Elaboración propia. (2026). *Primera descomposición de casos de uso del sistema AgroClima GT* [Diagrama PlantUML].

Figura 4. *CDU 100: Acceder al sistema*



Elaboración propia. (2026). **Diagrama expandido del CDU 100: Acceder al sistema** [Diagrama PlantUML].


Figura 5. *CDU 200 - Analizar rendimiento agrícola*



Elaboración propia. (2026). **Diagrama expandido del CDU 200: Analizar rendimiento agrícola** [Diagrama PlantUML].

CDU 300 - Consultar pronóstico y apoyo agronómico


Figura 6. *Diagrama expandido del CDU 300: Consultar pronóstico y apoyo agronómico*



Elaboración propia. (2026). **Diagrama expandido del CDU 300: Consultar pronóstico y apoyo agronomico** [Diagrama PlantUML].

CDU 400 - Monitorear sensores y alertas


Figura 7. *Diagrama expandido del CDU 400: Monitorear sensores y alertas.*



Elaboración propia. (2026). **Diagrama expandido del CDU 400: Monitorear sensores y alertas** [Diagrama PlantUML].

Diagrama expandido del CDU 500: Consultar resultados y datos.


Figura 8. *CDU 500 - Consultar resultados y datos*



Elaboración propia. (2026). **Diagrama expandido del CDU 500: Consultar resultados y datos** [Diagrama PlantUML].

Diagrama expandido del CDU 600: Administrar plataforma y modelo.


Figura 9. *CDU 600 - Administrar plataforma y modelo*



Elaboración propia. (2026). **Diagrama expandido del CDU 600: Administrar plataforma y modelo** [Diagrama PlantUML].

Diagrama de despliegue local del prototipo

Figura 10. *Diagrama de despliegue local del prototipo AgroClima GT.*



Elaboración propia. (2026). **Diagrama de despliegue local del prototipo AgroClima GT** [Diagrama PlantUML].

4.2. Selección y justificación del área de estudio

El prototipo trabaja a nivel municipal, por lo que el área de estudio se define a partir de los municipios disponibles en el dataset procesado. Esta unidad espacial permite relacionar variables climáticas, de suelo y cultivo con resultados de rendimiento agrícola. Cuando se usa un municipio específico como caso de estudio, este funciona como ejemplo de aplicación dentro de una cobertura más amplia del dataset.


La selección del área se justifica por la importancia de analizar condiciones agroclimáticas que afectan rendimiento, estrés hídrico, temperatura, lluvia y riesgo agrícola. El sistema permite ampliar el análisis a otros municipios siempre que existan datos compatibles.

4.3. Diseño del pipeline de datos y flujo operacional del sistema

El pipeline operativo inicia con fuentes climáticas y edáficas, continúa con el procesamiento local de archivos y termina en la predicción y visualización web. ERA5-Land, NASA POWER, SoilGrids e INSIVUMEH procesado alimentan el dataset. Luego, XGBoost usa ese dataset para entrenar el modelo de rendimiento. Durante la ejecución, FastAPI carga el modelo y responde a las consultas del frontend.

El flujo también incorpora Open-Meteo para pronóstico y Arduino por USB o simulación para lecturas de sensores. Las predicciones, lecturas y datos operativos pueden guardarse en PostgreSQL, mientras que los modelos y métricas se conservan en archivos locales.

Figura 11. *Pipeline operativo del sistema.*



Elaboración propia. (2026). **Pipeline operativo del sistema AgroClima GT** [Diagrama]. Tesis de prototipo AgroClima GT.

4.4. Desarrollo del motor de detección de anomalías y generación de alertas

El motor de análisis combina validación de entradas, predicción de rendimiento, detección de anomalías y recomendaciones. XGBoost estima el rendimiento esperado, mientras que Isolation Forest apoya la identificación de condiciones atípicas o lecturas fuera del comportamiento esperado.

Las alertas se presentan como apoyo a la decisión. El sistema muestra advertencias en la plataforma y puede enviar correos cuando existe configuración SMTP. La generación de alertas se basa en el resultado del modelo, rangos de variables y reglas agronómicas incluidas en los archivos locales de recomendaciones.

4.5. Integración de sensores IoT y transmisión de datos

La integración de sensores se implementa en software mediante Arduino por puerto serial, simulación de lecturas y comunicación con el backend. Esta capa permite probar el flujo de adquisición de datos sin depender todavía de una instalación física en parcelas. Las variables consideradas en el diseño del módulo son temperatura, luz, humedad de suelo y color/pH.

El componente físico se mantiene como etapa de validación posterior. La instalación en campo requiere montaje, calibración, pruebas de estabilidad y comparación con instrumentos de referencia.

Figura 12. Alcance del componente de sensores.

Elemento	Estado en el prototipo	Uso
Arduino	Integrado por software	Lectura local por USB y simulación.
WebSocket	Implementado	Visualización de lecturas en vivo.
Sensores físicos	Diseño propuesto	Montaje y calibración posterior.
Red inalámbrica	Evolución futura	Ampliación para campo.
Validación de campo	Pendiente	Evaluación física del sistema.

Elaboración propia. (2026). Alcance del componente de sensores en AgroClima GT [Tabla]. Tesis de prototipo AgroClima GT.

4.6. Diseño de la interfaz

La interfaz web traduce datos técnicos en información comprensible para el usuario. En sistemas de soporte a decisiones agrícolas, las visualizaciones ayudan a conectar datos complejos con recomendaciones concretas (Gutiérrez et al., 2022). AgroClima GT aplica este principio mediante dashboard, pronóstico, alertas, reportes, modelos, mapa de riesgo, módulo Arduino y panel administrativo.


El dashboard permite ingresar variables y obtener una predicción. Forecast muestra pronóstico meteorológico. Alerts presenta advertencias y recomendaciones. RiskMap permite interpretación espacial. Arduino muestra lecturas locales o simuladas. Admin concentra seguimiento de datasets, predicciones, lecturas y estado del modelo.

Tabla 12. *Módulos de interfaz y aporte al usuario.*

Módulo	Aporte
Dashboard	Predicción de rendimiento y resumen de variables.
Forecast	Pronóstico meteorológico.
Alerts	Advertencias y recomendaciones.
RiskMap	Visualización espacial por municipio.
Arduino	Lecturas locales o simuladas.
Admin	Seguimiento técnico de datos y modelo.

Elaboración propia. (2026). Módulos de interfaz y apoyo a decisiones en AgroClima GT [Tabla]. Tesis de prototipo AgroClima GT.


Figura 13. *Pantalla de inicio de sesión*



Elaboración propia. (2026). Pantalla de inicio de sesión de AgroClima GT [Figura]. Prototipo AgroClima GT.

La figura muestra la pantalla de inicio de sesión de AgroClima GT. Esta imagen evidencia que la plataforma cuenta con acceso controlado y separación básica de uso, permitiendo diferenciar el ingreso del usuario general y del administrador. También sirve como primera evidencia visual de la interfaz del prototipo.

Figura 14. *Dashboard principal*




Elaboración propia. (2026). **Dashboard principal de AgroClima GT** [Captura de pantalla]. Prototipo AgroClima GT.


La figura muestra el dashboard principal, donde el usuario ingresa municipio, cultivo y variables agroclimáticas. Esta pantalla concentra el flujo principal de uso del prototipo, ya que desde allí se envían datos al backend y se obtiene una respuesta del modelo predictivo.

muestra el resultado generado después de ejecutar una predicción. En esta vista se observa el rendimiento estimado, el nivel de riesgo y la recomendación generada por el sistema.

Figura 15. *Resultado de predicción*




Elaboración propia. (2026). **Resultado de predicción de rendimiento en AgroClima GT** [Captura de pantalla]. Prototipo AgroClima GT.



Elaboración propia. (2026). **Resultado de predicción de rendimiento en AgroClima GT** [Captura de pantalla]. Prototipo AgroClima GT.

Las figuras muestran el resultado generado después de ejecutar una predicción. En esta vista se observa el rendimiento estimado, el nivel de riesgo y la recomendación generada por el sistema.


Figura 16. *Módulo de pronóstico*



Elaboración propia. (2026). **Módulo de pronóstico meteorológico en AgroClima GT** [Captura de pantalla]. Prototipo AgroClima GT.

Figura muestra la vista de pronóstico meteorológico del prototipo. Esta pantalla presenta información climática de corto plazo consultada mediante Open-Meteo y la organiza para apoyar decisiones relacionadas con cultivo, riego, riesgo climático y planificación agrícola.


Figura 17. *Módulo Arduino*



Elaboración propia. (2026). **Módulo Arduino con lectura local o simulada en AgroClima GT** [Captura de pantalla]. Prototipo AgroClima GT.


La figura muestra el módulo Arduino del prototipo. En esta pantalla se documenta la conexión local, el estado del dispositivo, la configuración de cultivo y municipio, y la simulación de lecturas.

Figura 18. *Módulo de alertas*



Elaboración propia. (2026). *Módulo de alertas y recomendaciones en AgroClima GT* [Captura de pantalla]. Prototipo AgroClima GT.

Figura 19. *Panel administrativo*



Elaboración propia. (2026). *Panel administrativo de AgroClima GT* [Captura de pantalla]. Prototipo AgroClima GT.

La figura muestra el panel administrativo de AgroClima GT. Esta pantalla permite consultar datasets, lecturas, predicciones, estado del modelo o información operativa del sistema. Su función es evidenciar que el prototipo contempla seguimiento técnico y administración interna.

4.7. Herramientas, frameworks y stack tecnológico utilizado

El stack tecnológico del prototipo se organiza en frontend, backend, base de datos, machine learning, sensores y despliegue. React y Vite construyen la

interfaz web; FastAPI y Uvicorn ejecutan la API; PostgreSQL 16 funciona como base de datos; Docker Compose facilita el entorno de base de datos; XGBoost e Isolation Forest cubren predicción y anomalías; PySerial permite comunicación con Arduino; y GitHub Pages sirve como opción para publicar el frontend estático.

Esta selección permite construir un prototipo completo con herramientas abiertas y separadas por responsabilidad. La arquitectura resultante puede ejecutarse localmente y también evolucionar hacia un despliegue más formal del backend y la base de datos.

5. ANALISIS DE RESULTADOS Y VALIDACION


5.1. Evaluacion del desempeño de los modelos

La evaluación interna muestra que XGBoost obtuvo mejor desempeño que Random Forest sobre el dataset construido. XGBoost alcanzó R^2 de 0.7157, MAE de 4.86 y RMSE de 6.04, mientras que Random Forest obtuvo R^2 de 0.4485, MAE de 6.84 y RMSE de 8.42. Estos resultados respaldan la selección de XGBoost como modelo principal del prototipo.

La evaluación corresponde al dataset del proyecto y refleja desempeño técnico interno. La validación agrícola final requiere contrastar las predicciones con datos reales de producción observados en campo.

La figura muestra la comparación de métricas entre modelos evaluados. Esta imagen sirve para respaldar la selección de XGBoost como modelo principal, ya que presenta mejores resultados internos frente a Random Forest en R^2 , MAE y RMSE.

Figura 20. Comparación de modelos




Elaboración propia. (2026). **Comparación de modelos predictivos en AgroClima GT** [Captura de pantalla]. Prototipo AgroClima GT.

5.2. Resultados de detección de anomalías térmica

La detección de anomalías térmicas se presenta como resultado funcional preliminar. El sistema puede evaluar entradas o lecturas simuladas que se alejan de rangos esperados y reflejar esa condición en la lógica de alerta o recomendación. Isolation Forest aporta el mecanismo para identificar comportamiento atípico dentro del flujo del prototipo.


Los resultados actuales permiten comprobar funcionamiento del módulo, mientras que la validación con eventos térmicos reales requiere datos etiquetados de campo.

Figura 21. *Prueba funcional de anomalía o alerta*



Elaboración propia. (2026). **Prueba funcional de anomalía o alerta en AgroClima GT** [Captura de pantalla]. Prototipo AgroClima GT.

Figura 22. *Correo de prueba o alerta enviada*



Elaboración propia. (2026). **Correo de prueba o alerta enviada desde AgroClima GT** [Captura de pantalla]. Prototipo AgroClima GT.

En esta imagen muestra el resultado de una alerta enviada por correo o la prueba de configuración SMTP. Esta imagen sirve para documentar que el sistema puede pasar de la detección de una condición de riesgo a un mecanismo de notificación para el usuario o administrador.

5.3. Análisis de efectividad en la detección de riesgo

La detección de riesgo de bajo rendimiento se basa en la salida del modelo XGBoost y en las recomendaciones asociadas a las variables ingresadas. Cuando el sistema estima un rendimiento bajo o identifica condiciones fuera de

rango, la interfaz muestra información interpretable para apoyar la toma de decisiones.

La efectividad funcional se observa en la coherencia entre variables ingresadas, rendimiento estimado, nivel de riesgo y recomendación. La efectividad agronómica completa requiere evaluación con productores, técnicos o registros reales de rendimiento.

5.4. Validación del sistema de alertas en el caso de estudio

La validación del sistema de alertas se realiza mediante escenarios funcionales. Se selecciona un municipio y cultivo, se ingresan condiciones de riesgo o se simula una lectura, y el sistema genera una alerta o recomendación cuando corresponde. Este proceso verifica que la lógica implementada opere de forma consistente dentro del prototipo.

La validación operativa en campo requiere sensores instalados, eventos observados, calibración de lecturas y comparación con resultados reales.

5.5. Discusión sobre factibilidad, escalabilidad y limitaciones

AgroClima GT demuestra factibilidad técnica al integrar fuentes agroclimáticas, procesamiento de datos, modelo predictivo, backend, base de datos, interfaz web y módulo de sensores en una sola plataforma. La arquitectura modular permite ampliar el sistema con nuevas fuentes, más municipios, sensores físicos validados y un despliegue backend más robusto.

Las principales limitaciones son la falta de validación física de sensores en campo, la dependencia de datos procesados, la ausencia de eventos reales etiquetados para anomalías, la separación entre frontend estático y backend ejecutado como servicio aparte, y la falta de evaluación con productores. Estas limitaciones delimitan el alcance académico del prototipo y marcan las siguientes etapas de desarrollo.

REFERENCIAS

Docker. (s.f.). **How Compose works**. Docker Docs. Recuperado el 27 de abril de 2026, de <https://docs.docker.com/compose/intro/compose-application-model/>

FastAPI. (s.f.). **Features**. FastAPI documentation. Recuperado el 27 de abril de 2026, de <https://fastapi.tiangolo.com/features/>

GitHub. (s.f.). **GitHub Pages documentation**. GitHub Docs. Recuperado el 27 de abril de 2026, de <https://docs.github.com/pages>

Gutiérrez, F., Htun, N. N., Schlenz, F., Kasimati, A., & Verbert, K. (2022). Developing visual-assisted decision support systems across diverse agricultural use cases. **Agriculture*, 12*(7), 1027. <https://doi.org/10.3390/agriculture12071027>

ISRIC. (2025). **SoilGrids documentation**. <https://docs.isric.org/globaldata/soilgrids/>

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. En **Proceedings of the 8th IEEE International Conference on Data Mining** (pp. 413-422). IEEE. <https://doi.org/10.1109/ICDM.2008.17>

Muñoz-Sabater, J., Dutra, E., Agustí-Panareda, A., Albergel, C., Arduini, G., Balsamo, G., Boussetta, S., Choulga, M., Harrigan, S., Hersbach, H., Martens, B., Miralles, D. G., Piles, M., Rodríguez-Fernández, N. J., Zsoter, E., Buontempo, C., & Thépaut, J.-N. (2021). ERA5-Land: A state-of-the-art global reanalysis dataset for land applications. **Earth System Science Data*, 13*(9), 4349-4383. <https://doi.org/10.5194/essd-13-4349-2021>

NASA POWER. (s.f.). **Data services: API overview**. NASA POWER Docs. Recuperado el 27 de abril de 2026, de <https://power.larc.nasa.gov/docs/services/api/>

Open-Meteo. (s.f.). **Weather Forecast API documentation**. Recuperado el 27 de abril de 2026, de <https://open-meteo.com/en/docs>

PlantUML. (s.f.). **PlantUML at a glance**. Recuperado el 27 de abril de 2026, de <https://plantuml.com/>

React. (s.f.). **Quick start**. React documentation. Recuperado el 27 de abril de 2026, de <https://react.dev/learn>

scikit-learn Developers. (s.f.). **IsolationForest**. scikit-learn documentation. Recuperado el 27 de abril de 2026, de <https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.IsolationForest.html>

The PostgreSQL Global Development Group. (2025). **PostgreSQL 16.10 documentation**. <https://www.postgresql.org/docs/16/>

XGBoost Developers. (s.f.). **XGBoost documentation**. Recuperado el 27 de abril de 2026, de <https://xgboost.readthedocs.io/en/stable/>

AgGateway. (2025). *Data ethics and stewardship white paper*. AgGateway.
[https://aggateway.org/Portals/1010/WebSite/Newsroom/ComKit/White%20Papers/Data%20Ethics%20and%20Stewardship%20White%20Paper%20FINAL%20\(w%20citations\).pdf](https://aggateway.org/Portals/1010/WebSite/Newsroom/ComKit/White%20Papers/Data%20Ethics%20and%20Stewardship%20White%20Paper%20FINAL%20(w%20citations).pdf)

Ahmad, M., Imran, K., Attar, H., & Solyman, A. (2025). Isolation forest-based anomaly detection through generation offers and optimal dispatch data. En *2025 International Conference on Emerging Power Technologies (ICEPT)*. IEEE.
<https://doi.org/10.1109/ICEPT66058.2025.11036212>

Augustin, A., Díaz, J., González, L., & Torres, M. (2023). A systematic literature review of LoRaWAN: Sensors and applications. *Sensors*. <https://pmc.ncbi.nlm.nih.gov/articles/PMC10611380/>

Banco Mundial. (2024). *Guatemala: Trends & variability (ERA5)*. Climate Change Knowledge Portal.
<https://climateknowledgeportal.worldbank.org/country/guatemala/trends-variability-historical>

Blinnikov, M., Maltsev, G., & Khorov, E. (2022). Performance comparison of NB-Fi, Sigfox, and LoRaWAN. *Sensors*, 22(24).
<https://pmc.ncbi.nlm.nih.gov/articles/PMC9782702/>

Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on Loess. *Journal of Official Statistics*, 6(1), 3–73.

Constante-Prócel, P., Constante-Prócel, J., Gordón, C., Acurio, A., & Escobar-Segovia, K. (2022). LoRa network-based system for monitoring the agricultural sector in Andean areas: Case study Ecuador. *Sensors*, 22(18), 6743. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9505347/>

Davoli, L., Martalò, M., Cilfone, A., Belli, L., Ferrari, G., Pradeep, P., & Alur, S. (2020). LoRaFarM: A LoRaWAN-based smart farming modular IoT architecture. *Sensors*, 20(7), 2028.
<https://pmc.ncbi.nlm.nih.gov/articles/PMC7180486/>

Deepika, K., & Renuka Prasad, B. (2023). IoT-based dashboards for monitoring connected farms using free software and open protocols. En I. J. Jacob, S. Kolandapalayam Shanmugam, & I. Izonin (Eds.), *Data*

Intelligence and Cognitive Informatics. Algorithms for Intelligent Systems. Springer. https://doi.org/10.1007/978-981-19-6004-8_43

Evtimov, G., Yordanov, V., & Milev, G. (2023). Outlier detection in time-series receive signal strength observation using Z-score method with Sn scale estimator for indoor localization. *Applied Sciences*, 13(6), 3900. <https://doi.org/10.3390/app13063900>

Friha, O., Ferrag, M. A., Shu, L., Maglaras, L., & Wang, X. (2021). Internet of Things for the future of smart agriculture: A comprehensive survey of emerging technologies. *IEEE/CAA Journal of Automatica Sinica*, 8(4), 718–752. <https://doi.org/10.1109/JAS.2021.1003925>

Gyrard, A., Datta, S. K., Bonnet, C., & Baber, K. (2019). Design methodology of microservices to support predictive analytics for IoT applications. *Sensors*, 19(1). <https://pmc.ncbi.nlm.nih.gov/articles/PMC6308717/>

Gutiérrez, F., Htun, N. N., Schlenz, F., Kasimati, A., & Verbert, K. (2022). Developing visual-assisted decision support systems across diverse agricultural use cases. *Agriculture*, 12(7), 1027. <https://doi.org/10.3390/agriculture12071027>

Haque, A., & Soliman, H. (2025). A transformer-based autoencoder with Isolation Forest and XGBoost for malfunction and intrusion detection in wireless sensor networks for forest fire prediction. *Future Internet*, 17(4), 164. <https://doi.org/10.3390/fi17040164>

Hassan, A., et al. (2024). A systematic review of IoT in agriculture. *Journal of Smart Manufacturing Systems*. <https://doi.org/10.1016/j.jsms.2024.01.001>

He, X., Deng, S., Luo, S., Lou, T., Shi, Y., & Gu, B. (2023). OneShotSTL: One-shot seasonal-trend decomposition for online time series anomaly detection and forecasting. *Proceedings of the VLDB*

Endowment, 16(6), 1399–1412. <https://www.vldb.org/pvldb/vol16/p1399-he.pdf>

Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>

Hussain, S. J., et al. (2023). At the confluence of artificial intelligence and edge computing in IoT-based applications: A review and new perspectives. *Sensors*, 23(3), 1639. <https://doi.org/10.3390/s23031639>

Instituto Nacional de Sismología, Vulcanología, Meteorología e Hidrología. (2025). *Perspectiva climática mensual diciembre 2025* (PCM-202512). INSIVUMEH. <https://insivumeh.gob.gt/wp-content/uploads/2020/05/main-7.pdf>

Karunathilake, E. M. B. T., et al. (2025). Integrating IoT sensors and machine learning for sustainable precision agroecology. *Discover Agriculture*. <https://doi.org/10.1007/s44279-025-00247-y>

Kaya, Ş. M., İşler, B., Abu-Mahfouz, A. M., Rasheed, J., & AlShammari, A. (2023). An intelligent anomaly detection approach for accurate and reliable weather forecasting at IoT edges: A case study. *Sensors*, 23(5), 2426. <https://doi.org/10.3390/s23052426>

Kher, E. (2025, febrero 25). The legal landscape of data privacy in AI-driven precision agriculture. *Washington Journal of Law, Technology & Arts*. <https://wjta.com/2025/02/25/the-legal-landscape-of-data-privacy-in-ai-driven-precision-agriculture/>

Larocque, C., Goulet-Pelletier, J.-C., Morin-Lessard, E., & Mageau, M.-A. (2025). *Hidden leaks in time series forecasting: How data leakage affects LSTM evaluation across configurations and validation strategies* [Preprint]. arXiv. <https://arxiv.org/abs/2512.06932>

Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation forest. En *Proceedings of the 8th IEEE International Conference on Data Mining* (pp. 413–422). IEEE. <https://doi.org/10.1109/ICDM.2008.17>

Madhu Shree, M., & Dechamma, M. P. (2023-24). *Time series-based analysis of energy consumption: Forecasting and anomaly detection using modified LSTM and Isolation Forest* (Project Reference No. 47S_MSC_0138). 47th Series Student Project Programme, Department of Data Science, Reva University.

Mayeregger, E. (2021, septiembre 27). *Experiencia de articulación: Sistemas de monitoreo y alerta, Mesas Técnicas Agroclimáticas y Planes de Acción Anticipatoria* [Presentación]. Serie Gestión del Riesgo y Resiliencia en la Agricultura, FAO. https://www.fao.org/fileadmin/user_upload/faoweb/CapacitacionRLC/serie_GDR/webinar2/EdgarMayeregger_27_9_21.pdf

Mekki, K., Bajic, E., Chaxel, F., & Meyer, F. (2020). Energy consumption analysis of LPWAN technologies and lifetime estimation for IoT application. *Sensors*, 20(18). <https://pmc.ncbi.nlm.nih.gov/articles/PMC7506725/>

Miller, A., et al. (2025). IoT and AI transforming precision agriculture. *Sensors*, 25(12), 3583. <https://doi.org/10.3390/s25123583>

Ministerio de Agricultura, Ganadería y Alimentación. (2022). *Perspectiva agroclimática 2022*. MAGA. <https://www.maga.gob.gt/download/perspectiva-agro-22.pdf>

Ministerio de Agricultura, Ganadería y Alimentación / CIEA. (2026). *Informe agroclimático No. 1-2026*. MAGA. <https://www.maga.gob.gt/download/informe1-26.pdf>

Ministerio de Agricultura, Ganadería y Alimentación. (2024). *El cultivo de papa se desarrolla en el altiplano del país*. MAGA.

<https://www.maga.gob.gt/el-cultivo-de-papa-se-desarrolla-en-el-altiplano-del-pais/>

Ministerio de Agricultura, Ganadería y Alimentación / VIDER. (2026, febrero 19). *Estaciones meteorológicas inteligentes fortalecerán producción agrícola*. MAGA.

<https://www.maga.gob.gt/sitios/vider/estaciones-meteorologicas-inteligentes-fortaleceran-produccion-agricola/>

Monteiro, T. V. P., Castor, G. J. B. C., Castillo Correa, C. G., Arias, H. R. C., Ñaupari Huatuco, D. Z., & Molina Rodriguez, Y. P. (2025). A hybrid machine learning framework for electricity fraud detection: Integrating Isolation Forest and XGBoost for real-world utility data. *Energies*, 18(23), 6249. <https://doi.org/10.3390/en18236249>

Muñoz-Sabater, J., Dutra, E., Agustí-Panareda, A., Albergel, C., Arduini, G., Balsamo, G., Boussetta, S., Choulga, M., Harrigan, S., Hersbach, H., Martens, B., Miralles, D. G., Piles, M., Rodríguez-Fernández, N. J., Zsoter, E., Buontempo, C., & Thépaut, J.-N. (2021). ERA5-Land: A state-of-the-art global reanalysis dataset for land applications. *Earth System Science Data*, 13(9), 4349–4383. <https://doi.org/10.5194/essd-13-4349-2021>

Prasetya, D. A., Nguyen, P. T., Faizullin, R., Iswanto, I., & Armay, E. F. (2022). Design of IoT monitoring system based on LoRaWAN architecture for smart green house. *IOP Conference Series: Earth and Environmental Science*, 1012(1), 012090. <https://doi.org/10.1088/1755-1315/1012/1/012090>

Programa de las Naciones Unidas para el Medio Ambiente. (2022). *Climate information and early warning systems*. UNEP. <https://www.unep.org/topics/climate-action/climate-transparency/climate-information-and-early-warning-systems>

Secretaría de Planificación y Programación de la Presidencia. (2021). *Informe Guatemala 2021: Cambio climático*. SEGEPLAN. https://portal.segeplan.gob.gt/segeplan/Informe_Guatemala2021_CC.pdf

Sensirion AG. (2023). *SHT31: Humidity and temperature sensor* [Datasheet]. Sensirion. <https://sensirion.com/products/catalog/SHT31-DIS/>

Sezen, İ., Unal, A., & Deniz, A. (2020). Anomaly detection by STL decomposition and extended Isolation Forest on environmental univariate time series. *EGU General Assembly 2020*, EGU2020-18471. <https://doi.org/10.5194/egusphere-egu2020-18471>

Thalheimer, L., Simperingham, E., Patt, A., & van den Homberg, M. (2025). The role of artificial intelligence for early warning systems: Status, applicability, guardrails, and ways forward. *iScience*. <https://doi.org/10.1016/j.isci.2025.111955>

Tripathy, A. K., et al. (2025). Cloud–edge–device collaborative computing in smart agriculture: Architectures, applications, and future perspectives. *Frontiers in Plant Science*. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12558850/>

Unión Internacional para la Conservación de la Naturaleza. (2025, diciembre 16). *Intercambio de experiencias Guatemala-Panamá fortalece las Mesas Técnicas Agroclimáticas de la región*. UICN. <https://iucn.org/es/articulo/202512/intercambio-de-experiencias-guatemala-panama-fortalece-las-mesas-tecnicas>

Viguera, B., et al. (2019). Percepciones de pequeños productores sobre cambio climático. *Agronomía Mesoamericana*, 30(2). <https://doi.org/10.15517/am.v30i2.33938>

Apéndice 1.

Repositorio del proyecto

https://github.com/joshi20022021/PROYECTO_AGROCLIMA_TES

IS

CONCLUSIONES

- [illegible]

RECOMENDACIONES

- [illegible]

Las referencias deben estar sin numeración, en orden alfabético y con sangría francesa.

REFERENCIAS

Andritz, J. (2012). *Manual de operación y mantenimiento para turbina Pelton en Hidroeléctrica El Recreo*. Prentice Hall.

Arroyave, H. (2018). *Modelo del comportamiento de presas en cascada y visualización de software*. Prentice Hall. <https://www.andritz.com/no-index/pf-detail?productid=9224>

Grady, J. Her, M., Moreno, G., Pérez, C. y Yelinek, J. (2019). Emociones en los libros de cuentos: una comparación de libros de cuentos que representan grupos étnicos y raciales en los Estados Unidos. *Psicología de la cultura de los medios populares*, 8(3), 207-217. <https://doi.org/10.1037/ppm0000185>

Observe que en la lista de referencias debe utilizar el formato

Apellido, A.

Apellido e inicial del nombre

APÉNDICES

Estas páginas contienen información “elaborada por el estudiante” no debe continuar con la numeración de figuras y tablas.

Apéndice 1.

Título del apéndice 1

Debe utilizar el mismo formato para los títulos de tablas y figuras.

	REGISTRO GENERAL DE CAPACITACIÓN		CÓDIGO PP-08/19 Versión: 01 Página: 1/1
Nombre del instructor: _____ Tema de capacitación: _____ Hora de inicio: _____ Hora de finalización: _____ Fecha: _____			
PARTICIPANTES			
Nombre y apellido	Área	Función/puesto	Firma


Nota. Formato de registro de capacitación. Elaboración propia.

Título del apéndice 2

Nota. Control de descarte de toneles con materia prima. Elaboración propia.

Apéndice 3.

Planos del proyecto de introducción de agua potable



Debe colocar el apéndice de planos en página impar y la página siguiente en blanco.

La impresión de los planos queda a elección del estudiante, debe ser legible.

Nota. Juego de planos para la introducción de agua potable en la aldea El Aguacate, Mixco, Guatemala. Elaboración propia realizado con AutoCAD.


ANEXOS

Estas páginas contienen información “obtenida de una fuente externa” no debe continuar con la numeración de figuras y tablas.

Anexo 1.

Título del anexo 1

Debe utilizar el mismo formato para los títulos de tablas y figuras.



Nota. Diagrama de árbol de decisión lógica para determinación de PCC. Obtenido de la Comisión Guatemalteca de Normas. (2006). Norma COGUANOR NTG 34 243. (<https://www.mineco.gob.gt/comisi%C3%B3n-guatemalteca-de-normas>) consultado el 10 de junio de 2021.

Anexo 2.

Título del anexo 2


Hoja Maestra del plan HACCP 						
Fase	Peligro	Medidas preventivas	Límite crítico	Procedimiento de vigilancia	Medidas correctivas	Registro

Nota. Ejemplo de hoja maestra del sistema HACCP. Obtenido de la Comisión Guatemalteca de Normas. (2006). Norma COGUANOR NTG 34 243. (<https://www.mineco.gob.gt/comisi%C3%B3n-guatemalteca-de-normas>) consultado el 10 de junio de 2021.

**LA SIGUIENTE SECCIÓN ES PARA
COMPARTIR INDICACIONES GENERALES Y
EJEMPLOS, NO APLICA A ESTILOS
DEFINIDOS**

INDICACIONES GENERALES

Los colores y viñetas utilizados en este apartado NO son aplicables al trabajo de graduación, se aplicaron con el fin de aclarar las indicaciones



Márgenes del trabajo

- Ejemplo de subíndice de dos líneas o más

Observe que en el caso de subíndice de dos o más líneas debe quedar justificado, no debe quedar texto debajo de la numeración.

en esta fase se realizara la observacion indirecta de la literatura consultada y redacción de síntesis, resúmenes y extractos de información, de fuentes bibliográficas y digitales relacionados con el tema.

9.5.2. Fase 2: descripción de procedimientos existentes y determinación de la muestra de estudio por análisis bajo la metodología ABC / XYZ de las toneladas métricas de producción

El estudio se iniciará describiendo los procedimientos de planificación de la producción, compra de materia prima y material de empaque y el control de inventarios que utiliza la empresa MANTTRA, para determinar la situación existente con la finalidad de detectar las causas de la ineffectividad del proceso

- Cuando las figuras, tablas, apéndices y anexos abarcan más de una hoja, siga el siguiente formato.

Tabla 1.
Resumen de gastos mensuales

Concepto	Entradas			Salidas			Existencias		
	Cantidad	Precio	Total	Cantidad	Precio	Total	Cantidad	Precio	Total
Compra (I)	300	122	367		250	1.000			617
Dev. compra (I)					250	1.224			
				50	1.224	612	251	100	556
							250	122	

Tipo	Tamaño		Alineación	
	Máquina 1	Máquina 2	Máquina 1	Máquina 2
Char	8	8	8	64
Short	16	24	16	64
Int	32	48	32	64

Continuación de la tabla 1.
(Arial 12, al margen, sin negrita)

Concepto	Entradas			Salidas			Existencias		
	Cantidad	Precio	Total	Cantidad	Precio	Total	Cantidad	Precio	Total
Compra (I)	300	122	367		250	1.000			617
Dev. compra (I)					250	1.224			
				50	1.224	612	251	100	556
							250	122	

Tipo	Tamaño		Alineación	
	Máquina 1	Máquina 2	Máquina 1	Máquina 2
Char	8	8	8	64
Short	16	24	16	64
Int	32	48	32	64

Fuente: elaboración propia. (Arial 10).

Hasta el final de la tabla

Debe clasificar como **figura** lo siguiente:

- Gráficas
 - Barras, poligonal, de pie, entre otros
- Organigramas
- Diagramas de flujo
- Esquemas
- Dibujos o bocetos
- Imágenes
- Fotografías
- Mapas

Verificar la posición de la segunda viñeta.

- Hola
 - Adiós
 - Hasta pronto
 - ✓ Jamás
 - ❖ Suerte

NO debe utilizar listados (números, letras, incisos), únicamente se permite si es textual.

Debe clasificar como **tabla** a la disposición de datos en filas y columnas, aunque la fuente sea externa.

Ejemplo:


Recursos	Costo
Dos resmas de hojas	Q 100.00
Viáticos (combustible, hospedaje y alimentación)	Q 2,000.00
Tóner de impresora	Q 500.00
Asesor	Q 2,500.00
TOTAL	Q 5,100.00

No se permite utilizar páginas en horizontal dentro del trabajo de graduación, únicamente puede girar la figura o tabla (izquierda a derecha).

Ejemplo:

Figura 1.

Título de la figura



Nota. Esquema de medición de vibraciones en un motor eléctrico. Elaboración propia, realizado con Visio.

NORMAS APA, SÉPTIMA EDICIÓN

El estilo APA brinda una base para realizar una comunicación académica efectiva ya que orienta a los autores a presentar sus aportes de una manera clara y precisa. En el momento en el que el estilo funciona mejor, las ideas fluyen en un orden lógico, las fuentes de las cuales se ha obtenido la información se acreditan de una manera adecuada y los documentos se organizan de una forma consistente, los autores planifican el cumplimiento ético, informan de los detalles de su investigación con el fin que otros autores evalúen los resultados y lo más importante que otros autores repliquen y continúen con estos estudios. (APA, 2022)

En el ámbito académico es esencial reconocer a otros autores que contribuyeron en su trabajo, los autores en este sentido se aseguran de que los lectores entiendan la colaboración de trabajos anteriores. El estilo APA utiliza el sistema de citas autor–fecha, en donde una breve cita refiere al lector a la lista de referencias. Cada obra citada debe aparecer en la lista de referencias, y cada obra de la lista de referencias debe estar citada en el texto, tanto las paráfrasis como las citas textuales requieren de una referencia. (APA, 2021)

- Formas de citación


Las citas están relacionadas a las ideas que se obtienen de otras fuentes de información con una correcta atribución de los créditos de autoría. En el estilo APA, existen dos formas de atribuir importancia a una cita y dependerá de lo que se necesite enfatizar. Por un lado, se utiliza la citación narrativa, en la que se destaca el pensamiento o la posición específica de un autor y por otro lado, la cita parentética (o entre paréntesis) en la que se hace referencia a una idea en la que el autor tiene un papel secundario.

En las citas, además del énfasis, es importante determinar el procedimiento para incluir la información de otras fuentes. En este sentido, las citas pueden ser textuales o directas, cuando se utiliza la información tal y como se han expresado por otros autores y las citas parafraseadas, en las que reafirma la idea de otro en sus propias palabras. La paráfrasis le permite al autor resumir y sintetizar la información de otra fuente, enfocar la información significativa, comparar y contrastar detalles relevantes, manteniendo el sentido original. (APA, 2021)

“Cada obra citada en el texto debe figurar en la lista de referencias y cada obra en la lista de referencias debe ser citada en el texto” (APA, 2021).


Algunas excepciones:

- Las comunicaciones personales, son fuentes irrecuperables, se citan solo en el texto.



- Cita textual


Se refiere a extraer información de una fuente externa, para este tipo de cita es necesario incluir el apellido del autor, el año de la publicación e indispensable, el número de la página del documento.




- Cita textual corta (de menos de 40 palabras)

Cuando la cita textual tiene menos de 40 palabras se integra en el párrafo y coloca entre comillas inglesas (“ ”), sin cursiva. Se escribe con punto al finalizar la oración que incluye la cita.

Ejemplo 1(cita textual corta narrativa):




Ejemplo 2 (cita textual corta parentética):



- Cita textual larga (de más de 40 palabras)

Las citas textuales que tienen más de 40 palabras se escriben aparte del texto, con sangría de **0.5 (pulgada) = 1.27 cm** aplicada a todo el párrafo, no lleva comillas, conserva el tamaño de la fuente y el interlineado doble. El punto final se coloca antes de los datos de la cita. Si es necesario utilizar más de un párrafo, se debe aplicar una sangría adicional a la primera línea de cada párrafo adicional.

Ejemplo 1 (cita textual de más de 40 palabras, tipo narrativa)



Ejemplo 2 (cita textual de más de 40 palabras, tipo parentética):

Interlineado
doble

Sangría de
1.27 cm
aplicada a
todo el
bloque

Es un tipo de motor de corriente alterna en el que la corriente eléctrica del rotor necesaria para producir el torque es inducida por electromagnetismo de la bobina del estator. El motor de inducción puede obtener torque promedio diferente de cero en un amplio rango de velocidades mecánicas, las corrientes que circulan por el rotor se ajustan por el fenómeno de inducción electromagnética. Se fija la frecuencia de las corrientes en el estator ω_e , y se produce un campo electromagnético en el entrehierro de la máquina que gira mecánicamente con la frecuencia angular de estas corrientes. Como el rotor gira a la velocidad mecánica ω_m , los conductores del rotor cortan el campo magnético producido en el estator con una velocidad que es la diferencia entre ω_e y ω_m . La diferencia porcentual entre estas dos velocidades es la que actualmente se conoce como deslizamiento de la máquina. (Aller, 2004, p. 80)

Punto final
de la cita

Número de
página

Año


Apellido

- Parafraseo

Utiliza las ideas de otro autor, pero en palabras propias del autor, en esta cita es necesario incluir el apellido del autor y el año de publicación. **No** debe agregar el número de página.


Ejemplo 1 (paráfrasis narrativa)

En cuanto a la percepción visual, Rodas (1994) explica que la información óptica recibida será borrosa.



Ejemplo 2 (paráfrasis parentética)

En cuanto a la percepción visual, la información óptica recibida será borrosa (Rodas, 1994).



El sistema de autor-fecha presenta algunas variaciones las cuales dependen del tipo y la cantidad de autores:

Tipo de autor	Citación narrativa	Citación parentética	Observaciones
Un autor (libro, artículo científico, tesis)	López (2019)	(López, 2019)	
Dos autores	Camey y Sánchez (2014)	(Camey y Sánchez, 2014)	Latinos con “y” y extranjeros con “&”.
Tres o más autores en una misma cita.	López (2014); Martínez (2016); Osorio (2019)	(López, 2014; Martínez, 2016; Osorio, 2019)	
Tres o más autores, puede utilizar et al. desde la primera cita	Pérez et al. (2020)	(Pérez et al., 2020)	Solo si puede producir en el texto ambigüedad utilice todos los apellidos. Debe utilizar et al. únicamente para las citas.
Autor corporativo con abreviación (primera cita) / aplicable a página web	Organización Mundial de la Salud (OMS, 2016)	(Organización Mundial de la Salud [OMS], 2016)	
Siguientes citas	OMS (2016)	(OMS, 2016)	
Autor corporativo sin abreviación	Pontificia Universidad Javeriana (2019)	(Pontificia Universidad Javeriana, 2019)	
Mismo autor con la misma fecha de publicación	Morales (2017a) Morales (2017b)	(Morales, 2017a) (Morales, 2017b)	
Mismo autor con diferente fecha de publicación	Monzón (2019) Monzón (2020)	(Monzón, 2019) (Monzón, 2020)	Se ordena en la lista de referencia por la publicación más antigua.
Diferentes autores con el mismo apellido, se debe diferenciar por la inicial del nombre	A. Zúñiga (2018) P. Zúñiga (2019)	(A. Zúñiga, 2018) (P. Zúñiga, 2019)	En la lista de referencias se debe colocar Zuñiga, A. (2018) Zuñiga, P. (2019)
Publicaciones sin autor	Anónimo (2015)	(Anónimo, 2015)	
Publicaciones sin autor, es permitido utilizar el nombre de la publicación	Habilidades Interpersonales (2019)	(Habilidades Interpersonales, 2019)	Debe colocar en la lista de referencias el nombre de la publicación. Si el nombre fuera muy largo, puede acortar el nombre para citar en el texto.

Publicación sin fecha	Torres, (s.f.)	(Torres, s.f.)	
Cita sin número de página	Juárez (2018) “.... ” (párr. 7)	(Juárez, 2018, párr.7)	Puede especificar en la cita: párrafo, artículo, capítulo, diapositiva, tabla, entre otros.
Cita de cita	Andrade (2004) (como se cita en Díaz, 2010)	(Andrade, 2004, como se cita en Díaz, 2010)	En las referencias debe estar la de Díaz (2010) *Si desconoce el año de la fuente primaria, omítalo en la citación en el texto.
Cita un periódico	González (2021)	(González, 2021)	(González, 2021, p. 7) Nota: solo se coloca el año, aunque en la referencia bibliográfica se coloca día mes y año.
Cita de una ley	Ley de transformación agraria (1962)	(Ley de transformación agraria, 1962)	Textual: (Ley de transformación agraria, 1962, Cap. XXIII, Art. 259)
Cita de varios documentos	Andrade (2020), Monroy (2018) y Girón (2019). *Pueden aparecer en cualquier orden.	(Andrade, 2020; Girón, 2019; Monroy, 2018) * orden alfabético	
Comunicación personal	J. Monterroso (comunicación personal, 15 de marzo de 2021)	(J. Monterroso, comunicación personal, 15 de marzo de 2021).	No se incluye en la lista de referencias

REFERENCIAS

Listado con la información completa de las fuentes citadas en el texto. Son necesarias para la atribución de los créditos de autoría en el caso que el lector necesite verificar las fuentes que sustentaron un trabajo.

Las referencias deben estar en **orden alfabético, sangría francesa, sin numerar y un espacio entre cada referencia**. Debe verificar cada dato que se requiere, debe colocar la información en el orden indicado. Se agregan algunos ejemplos de los datos necesarios para las referencias.

- **Libro con autor**

Apellido, A. (año). *Título del libro en cursiva*. Editorial.

Velásquez, C. (2016). *Comunicación lingüística: desarrollo de la competencia comunicativa en la universidad*. Ediciones Morata, S. L.

- **Libro con 3 autores o más (&)**

Apellido, A., Apellido. B., & Apellido, C. (año). *Título del libro en cursiva*. Editorial.

Velásquez, C., Morataya, J., & Gutiérrez, O. (2016). *Comunicación lingüística: desarrollo de la competencia comunicativa en la universidad*. Ediciones Morata, S. L.

- **Anónimo (ejemplo anterior)**

Habilidades interpersonales (2019). Editorial. <https://grupo-pya.com/habilidades-interpersonales>

- **Libro obtenido de internet**

Apellido, A. A. (año). *Título del libro en cursiva*. Editorial. URL

Pérez, F. (2012). *La guerra de los capinegros*. Alfaguara. https://doi.org/10.1007/978-3-030-19685-1_3

- **Ley**

Nombre de la ley o número de la ley y denominación oficial. (fecha). Nombre de la entidad que promulga la ley. Título de la publicación en que aparece oficialmente y número de publicación. País. URL.

Ley Orgánica del Banco de Guatemala. Decreto 16-2005. (15 de noviembre de 2005). Congreso de la República. Diario de Centroamérica No. 95 tomo CCCXVIII. Guatemala. <https://legal.dca.gob.gt/>

- **Artículo de revista**

Apellido, A. (año). Título del artículo. *Nombre de la revista en cursiva*, volumen(número), intervalo de páginas.

Adams, R. (2014). Ladinización e historia: el caso de Guatemala. *Mesoamérica*, 15(28), 289-304.

- **Artículo de revista en línea**

Apellido, A. (año). Título del artículo. *Nombre de la revista en cursiva*, volumen(número), intervalo de páginas. URL

Lagos, J. (2017). Concepciones sobre docencia en el nuevo marco regulatorio del sistema escolar chileno. *Revista de Psicología* 26(1), 1-13.
<http://www.revistapsicologia.uchile.cl/php/RDP/article/46693/>

- **Tesis impresa**

Apellido, A. (Año). *Título de la tesis* [Tesis de pregrado, maestría o doctoral, nombre de la institución que otorga el título]. Nombre de la base de datos.

Rodríguez, B. (2007). *La pobreza en hogares liderados por mujeres*. [Tesis de doctorado, Universidad de San Carlos de Guatemala]. Repositorio institucional.

- **Tesis electrónica**

Apellido, A. (Año). *Título de la tesis*. [Tesis de pregrado, maestría o doctoral, nombre de la institución que otorga el título]. Archivo digital. URL.

Díaz, J. (2003). *Consecuencias del conflicto armado en la salud mental de los achí de Rabinal, Baja Verapaz 1980-2000*. [Tesis de pregrado, Universidad de San Carlos de Guatemala]. Archivo digital.
http://biblioteca.usac.edu.gt/tesis/14/14_0241.pdf

- **Diccionario en línea sin autor**

Autor corporativo (ciudad). Título de la entrada. *Nombre del diccionario en cursiva*. Recuperado el (día, mes y año) de URL.

Real Academia Española (Madrid). Signos ortográficos. *Diccionario panhispánico de dudas*. Recuperado el 14 de febrero de 2019 de
<https://www.rae.es/dpd/signos%20ortogr%C3%A1ficos>

Nota. Cuando se cita una versión estable o archivada de la obra, no se necesita una fecha de recuperación, por lo tanto, se utiliza la fecha de recuperación cuando una obra de consulta en línea se actualiza continuamente.

- **Wikipedia (fuente secundaria)**

Pintura al óleo. (8 de diciembre de 2019). En *Wikipedia*.
<https://en.wikipedia.org/w/index.php?title=Oilpainting&oldid=929802398>

- Cita parentética: ("Pintura al óleo", 2019)
- Cita narrativa: "Pintura al óleo" (2019)

- **Publicaciones o informes con autor institucional**

Nombre de la institución (año). Título del documento (si existe número de publicación se escribe entre paréntesis). URL.

Ministerio de Economía (2008). *Política nacional para el desarrollo de las micro, pequeñas y medianas empresas*. <https://www.mineco.gob.gt/node/157>

- **Periódico impreso**

Apellido, A. (día, mes y año). Título del artículo. *Nombre del periódico*, página sin abreviación.

Vásquez, E. (7 de octubre de 2018). Violencia y abandono son las causas que llevan a las niñas a unirse a las maras. *elPeriódico*, 6.

- **Periódico en línea**

Apellido, A. (día, mes y año). Título del artículo. *Nombre del periódico en cursiva*. URL.

Ramírez, S. (26 de noviembre de 2017). La botella en el mar. *elPeriódico*.
<https://elperiodico.com.gt/category/opinion/opiniones-de-hoy/>

- **Página web institucional**

Nombre de la institución. (fecha). Título del documento en cursiva. URL.

Instituto de Hidrología, Meteorología y Estudios Ambientales. Bustos, A. (marzo de 2017). *Cambio climático*. <http://www.ideam.gov.co/web/atencion-y-participacion-ciudadana/cambio-climatico>.

- **Página web individual (blog)**

Apellido, A. (día, mes y año). Título de la publicación en cursiva. Nombre del sitio web.
URL.

Bustos, A. (9 de marzo de 2017). *La e protética*. Nexus Radical. <https://blog.lenguaje.com/2017/la-e-protetica/>

- **Simposios, conferencias y congresos**

Apellido, A. (fecha). Título de la ponencia [tipo de contribución]. *Título del simposio, conferencia o congreso*. Ciudad, país. URL.

Rojas, C. y Vera, N. (del 1 al 2 de octubre de 2019) ABMS Automatic BLAST for Massive Sequencing [sesión de congreso]. *II Congreso Colombiano de Biología Computacional y Bioinformática*. Manizales, Colombia.
<https://sitios.ces.edu.co/simposiobullying/index.php>

- **Documento en otro idioma**

Apellido, A. (año). *Título del documento en cursiva* [traducción en español]. Editorial.

Piaget, J., & Inhelder, B. (1966). *La psychologie de l'enfant* [Psicología del infante]. Quadrige.

Nota:

Si existiera alguna duda o caso especial que no esté descrito en la plantilla, por favor contactar al personal **interno** de la Unidad de Lingüística de la Facultad de Ingeniería.