



Universidad de San Carlos de Guatemala
Facultad de Ingeniería
Escuela de Ingeniería en Ciencias y Sistemas

**DESARROLLO DE UN SISTEMA BASADO EN MACHINE LEARNING PARA LA
DETECCION TEMPRANA DE ESCENARIOS DE BAJO RENDIMIENTO AGRICOLA
EN ZONAS AGROCLIMATICAS DE GUATEMALA**

Edgar Josías Cán Ajquejay

Asesorado por el Ing. Sergio Leonel Gomez Bravo

Titulo del Proyecto: Desarrollo de un sistema basado en Machine Learning para la detección temprana de escenarios de bajo rendimiento agrícola en zonas agroclimáticas de Guatemala

Breve descripción del proyecto

El proyecto consiste en el desarrollo de una solución tecnológica integral que combina Machine Learning (ML) e Internet de las Cosas (IoT) para la vigilancia agrícola. El sistema utiliza un dispositivo con sensores accesibles (temperatura, humedad ambiental/suelo y parámetros de altura) para capturar métricas del campo en tiempo real, las cuales se transmiten a una plataforma centralizada. Mediante modelos predictivos entrenados con datasets históricos del INSIVUMEH, el sistema compara las condiciones actuales con patrones de riesgo climático para detectar anomalías de forma temprana. Los resultados se visualizan en un dashboard de métricas que genera alertas automáticas, permitiendo una toma de decisiones informada antes de que el daño en los cultivos sea irreversible.

Objetivo General

Desarrollar una solución tecnológica orientada a la identificación de escenarios de bajo rendimiento agrícola en Guatemala mediante el análisis de registros climáticos y métricas en tiempo real.

Objetivos Específicos

1. Caracterizar el comportamiento climático y umbrales de riesgo en las zonas de interés del territorio guatemalteco a través del análisis de registros históricos.
2. Implementar un dispositivo de monitoreo para la obtención de variables ambientales locales en el sitio de estudio en tiempo real.
3. Evaluar el desempeño de modelos analíticos en la identificación de anomalías climáticas vinculadas al rendimiento agrícola.
4. Desarrollar una interfaz de visualización para el seguimiento de los indicadores generados por el sistema.

Antecedentes

En el año 2021, Gordillo y A. realizaron una investigación en la Universidad de San Carlos de Guatemala titulada: Red de sensores inalámbricos bajo protocolo LoRa y gestión de procesos para la analítica de datos mediante meta sistema operativo para monitoreo ambiental en invernaderos. Se hace referencia a este trabajo porque establece la base técnica para la implementación de hardware de bajo costo y protocolos de comunicación inalámbrica en el contexto rural guatemalteco, lo cual fundamenta la factibilidad del nodo sensor propuesto en este proyecto.

Posteriormente, Gera y Jain (2023) presentaron el estudio Predicting Crop Yield in Smart Agriculture Using IoT and Machine Learning for Sustainable Development. Se incluye esta investigación debido a que valida la integración de sensores de campo con modelos analíticos para mejorar la precisión en las estimaciones de rendimiento, demostrando que el procesamiento de datos históricos masivos es esencial para reducir la incertidumbre en la agricultura de precisión.

Por su parte, Quiroz-Valdez et al. (2024) implementaron un sistema de monitoreo IoT para la gestión de cultivos, detallado en su publicación sobre la transformación agrícola digital. Este estudio es relevante para el proyecto porque analiza cómo la arquitectura de almacenamiento en la nube y la visualización web facilitan la respuesta inmediata ante desviaciones térmicas, sirviendo como guía para el desarrollo del dashboard de alertas del prototipo.

Asimismo, Urbina Cienfuegos y Bravo Rivas (2025) llevaron a cabo una investigación titulada: Inteligencia Artificial: Machine Learning, para Detección Temprana de Plagas y Enfermedades. Se cita este antecedente porque resalta la importancia de incorporar métricas climáticas locales para aumentar la efectividad de los modelos preventivos en granos básicos, reforzando la necesidad de adaptar los algoritmos a la realidad ambiental de la región

centroamericana.

Finalmente, Wei, Shan y Zhen (2025) propusieron el marco IMSFNet, una red de agricultura inteligente que utiliza fusión de datos multimodales. Se hace referencia a este trabajo debido a que evalúa el uso de arquitecturas híbridas de inteligencia artificial para identificar variaciones complejas en la salud de los cultivos, proporcionando un referente científico sobre cómo superar las limitaciones de los umbrales estáticos tradicionales mediante el análisis de dependencias temporales.

Alcances y límites

Límites

- Obtención y limpieza de series temporales de temperatura, humedad y precipitación de los últimos 30 años (climatologías 1981-2010 y 1991-2020) para Guatemala.
- Focalización de la validación del prototipo en el Altiplano Occidental.
- Implementación de algoritmos de identificación de anomalías térmicas contextuales basados en datos históricos.
- Desarrollo de un dashboard interactivo que presente métricas de precisión y estados de riesgo.

Alcances

- La investigación se restringe a la fase de validación técnica y prototipo funcional.
- La captura de datos en tiempo real se encuentra supeditada a la disponibilidad de redes inalámbricas en los puntos de prueba.
- El sistema no incluye la ejecución de medidas de mitigación físicas automatizadas en los cultivos.
- El estudio utiliza recursos tecnológicos convencionales y bases de datos meteorológicas de acceso público

INDICE

ÍNDICE DE ILUSTRACIONES

GLOSARIO

RESUMEN

OBJETIVOS

INTRODUCCIÓN

1. MARCO CONTEXTUAL: AGRICULTURA Y CLIMA EN GUATEMALA

- 1.1. Importancia del sector agrícola en la economía nacional
- 1.2. Caracterización de las 8 regiones agroclimáticas (MAGA)
- 1.3. Problemática de las anomalías térmicas y heladas agrícolas
- 1.4. Vulnerabilidad de cultivos estratégicos (Maíz, Frijol, Café)
- 1.5. El rol del INSIVUMEH y MAGA en la vigilancia climática
- 1.6. Fenología y fases críticas de desarrollo ante el estrés térmico

2. MARCO TEÓRICO: MACHINE LEARNING Y DETECCIÓN DE ANOMALÍA

- 2.1. Fundamentos de Machine Learning para agricultura
- 2.2. Aprendizaje supervisado vs. no supervisado
- 2.3. Algoritmos para análisis de series temporales
 - 2.3.1. Redes LSTM (Long Short-Term Memory)
 - 2.3.2. Árboles de decisión y XGBoost
- 2.4. Técnicas de detección de anomalías (Isolation Forest y Z-Score)
- 2.5. Estado del arte: Sistemas de Alerta Temprana (SAT)
- 2.6. Descomposición de series temporales (Tendencia, estacionalidad y residuo)
- 2.7. Arquitectura de IoT y protocolos de comunicación (MQTT/LoRaWAN)

3. METODOLOGÍA Y PROCESAMIENTO DE DATOS

- 3.1. Tratamiento de datos y limpieza de series temporales
- 3.2. Técnicas de limpieza y tratamiento de series climáticas
- 3.3. Ingeniería de características (Horas frío y estrés térmico)
- 3.4. Estrategia de entrenamiento y validación de modelos

4. DISEÑO E IMPLEMENTACIÓN DEL PROTOTIPO

- 4.1. Arquitectura del sistema predictivo
- 4.2. Selección del área de estudio (Caso de estudio: Altiplano Occidental)
- 4.3. Desarrollo del motor de detección y generación de alertas
- 4.4. Interfaz de visualización para toma de decisiones

5. ANÁLISIS DE RESULTADOS Y VALIDACIÓN

- 5.1. Evaluación de métricas de desempeño (Precisión, F1-Score)
- 5.2. Análisis de efectividad en la detección de bajo rendimiento
- 5.3. Discusión sobre la factibilidad y escalabilidad del sistema

CONCLUSIONES

RECOMENDACIONES

REFERENCIAS

Cronograma de actividades

Table 1 Cronograma de actividades del proyecto de detección temprana de bajo rendimiento agrícola

Fase / Semana	Actividad Principal	Sub-tareas Técnicas	Fecha Inicio	Fecha Fin	Ref. Índice
S1: Inicio	Definición y Preliminares	Redacción de introducción, justificación y revisión de protocolos USAC.	01 de marzo	07 de marzo	1.1 - 1.2
S2: Contexto	Marco Agrícola Nacional	Estudio de las 8 regiones agroclimáticas y fenología de cultivos críticos. ¹	08 de marzo	13 de marzo	1.3 - 1.6
S3: Teoría I	Investigación de IA y ML	Documentación de modelos de series temporales y técnicas de detección de anomalías. ⁴	14 de marzo	20 de marzo	2.1 - 2.4
S4: Teoría II	Arquitectura IoT	Estudio de protocolos MQTT, sensores de bajo costo y sistemas de alerta (SAT).	21 de marzo	25 de marzo	2.5 - 2.7
S5: Datos	Adquisición de Registros	Descarga de datasets de NASA POWER, ERA5-Land y portal INSIVUMEH.	26 de marzo	01 de abril	3.1
S6: Limpieza	Preprocesamiento	Tratamiento de datos faltantes () e ingeniería de características climáticas. ¹⁰	02 de abril	08 de abril	3.2 - 3.3
S7: Modelado	Estrategia de ML	Diseño de partición de datos (80/20) y selección de métricas de validación ().	09 de abril	15 de abril	3.4
S8: Hardware	Ingeniería de Prototipo	Ensamblaje del nodo ESP32, programación de sensores y pruebas de telemetría.	16 de abril	25 de abril	4.1 - 4.2
S9: Desarrollo	Implementación Técnica	Desarrollo del motor de anomalías y construcción del Dashboard de visualización web.	26 de abril	03 de mayo	4.3 - 4.4



USAC
TRICENTENARIA
Universidad de San Carlos de Guatemala

Guatemala, 27 de febrero de 2026

Ingeniero
Carlos Alfredo Azurdia
Coordinador de Privados y Trabajos de Tesis
Escuela de Ingeniería en Ciencias y Sistemas
Facultad de Ingeniería - USAC

Respetable Ingeniero Azurdia:

Por este medio hago de su conocimiento que acepto asesorar el trabajo de investigación del estudiante **EDGAR JOSÍAS CÁN AJQUEJAY** con carné **202112012** y CUI **3114 76716 0409** titulado **"DESARROLLO DE UN SISTEMA BASADO EN MACHINE LEARNING PARA LA DETECCIÓN TEMPRANA DE ESCENARIOS DE BAJO RENDIMIENTO AGRÍCOLA EN ZONAS AGROCLIMÁTICAS DE GUATEMALA"**, así mismo me comprometo a ejercer mis funciones ajustándome a las fechas que en conjunto con el estudiante hemos definido en el plan de trabajo.

Al agradecer su atención a la presente, aprovecho la oportunidad para suscribirme,

Atentamente,

SERGIO LEONEL GOMEZ BRAVO
INGENIERO EN CIENCIAS Y SISTEMAS
CUI 12571

Ing. Sergio Leonel Gomez Bravo
Colegiado No.11671

Bibliografía

Wei, C., et al. (2025). Deep learning-based anomaly detection for precision field crop protection. *Frontiers in Plant Science*. <https://doi.org/10.3389/fpls.2025.1576756>

Urbina Cienfuegos, S. M., & Bravo Rivas, J. J. (2025). Inteligencia Artificial para Detección Temprana de Plagas y Enfermedades. *Revista INGENIO*. <https://revistadigital.uce.edu.ec/index.php/INGENIO/article/view/7221>

National Aeronautics and Space Administration. (s.f.). *NASA POWER data access viewer*. <https://power.larc.nasa.gov/>

Copernicus Climate Change Service. (s.f.). *ERA5-Land hourly data from 1950 to present*. <https://cds.climate.copernicus.eu/datasets/reanalysis-era5-land>

Climate Hazards Center. (s.f.). *CHIRPS version 3 precipitation data*. University of California, Santa Barbara. <https://www.chc.ucsb.edu/data/chirps3>

Quiroz-Valdez, J. A., et al. (2024). Implementación de un sistema de Monitoreo IoT para cultivos. *Pädi Boletín Científico*. <https://doi.org/10.29057/icbi.v12iEspecial4.13323>

Gera, R., & Jain, A. (2023). Predicting Crop Yield in Smart Agriculture Using IoT and Machine Learning. *CCIS, vol 1939*. https://doi.org/10.1007/978-3-031-47055-4_6

Gordillo, G. y A., C. (2021). Red de sensores inalámbricos bajo protocolo LoRa y gestión de procesos para la analítica de datos ambiental en invernaderos.. Citado en

<https://doi.org/10.29057/icbi.v12iEspecial4.13323>

Instituto Nacional de Sismología, Vulcanología, Meteorología e Hidrología (INSIVUMEH). (s.f.). *Registros históricos de temperatura, humedad y precipitación (1981–2010 y 1991–2020)*. https://insivumeh.gob.gt/?page_id=14371

Ministerio de Agricultura, Ganadería y Alimentación (MAGA). (s.f.). *Portal de datos abiertos: Reportes situacionales de granos básicos, precios y zonificación agrícola*. <https://www.maga.gob.gt/datos-abiertos-op/>

Instituto Privado de Investigación sobre Cambio Climático (ICC). (s.f.). *REDMET: Red de estaciones meteorológicas automáticas*. <https://redmet.org.gt>

Asociación Nacional del Café (ANACAFÉ). (s.f.). *Geoportal meteorológico para regiones cafetaleras de Guatemala*. <https://www.anacafe.org/geoportal/>